

融合虚拟对抗训练和均值教师模型的主导失稳模式识别半监督学习框架

张润丰¹, 姚伟^{1*}, 石重托¹, 汤涌², 文劲宇¹

- (1. 强电磁工程与新技术国家重点实验室(华中科技大学电气与电子工程学院), 湖北省 武汉市 430074;
2. 中国电力科学研究院有限公司, 北京市 海淀区 100192)

Semi-supervised Learning Framework of Dominant Instability Mode Identification Via Fusion of Virtual Adversarial Training and Mean Teacher Model

ZHANG Runfeng¹, YAO Wei^{1*}, SHI Zhongtuo¹, TANG Yong², WEN Jinyu¹

- (1. State Key Laboratory of Advanced Electromagnetic Engineering and Technology (School of Electrical and Electronic Engineering, Huazhong University of Science and Technology), Wuhan 430074, Hubei Province, China;
2. China Electric Power Research Institute, Haidian District, Beijing 100192, China)

ABSTRACT: Power grid simulation is of great significance to power system planning, operating, and control decision-making. It is an important step in simulation calculation to analyze the stability of power system and the dominant instability mode (DIM) according to the massive simulation data, so as to provide support for the subsequent formulation of emergency control decision tables. In this paper, deep learning was used to overcome the problem that traditional methods are difficult to effectively distinguish rotor angle instability and voltage instability in the actual power grid. In order to reduce the dependence of the deep neural networks on labeled samples, this paper proposed a semi-supervised learning framework based on mean teacher (MT) with the virtual adversarial training (VAT) model for the intelligent identification of DIM in simulation analysis. The VAT-MT model constructed a teacher network and a student network respectively. The model training was enhanced by applying small disturbance to the features of all samples, and then input into the two networks to calculate the consistency loss. At the same time, the maximum disturbance direction was calculated by VAT to improve the performance of the model. Case studies were conducted on the China Electric Power Research Institute 36-bus system and Northeast China Power Grid. The results show that the proposed method can effectively reduce the labeling cost, and has the ability to adapt to the actual power grid.

KEY WORDS: simulation data analysis; dominant instability mode; semi-supervised learning; mean teacher; virtual adversarial training

摘要: 电网仿真计算对电力系统规划、运行方式和控制决策制定具有重要的指导意义。在仿真计算中, 一个重要的步骤是根据海量暂稳仿真数据分析电力系统的稳定性以及主导失稳模式, 为后续制定紧急控制决策表提供帮助, 该文采用深度学习克服传统方法难以有效区分实际电网中功角失稳和电压失稳的问题。为降低深度神经网络对有标注样本的依赖, 进一步提出一种融合虚拟对抗训练(virtual adversarial training, VAT)和均值教师(mean teacher, MT)模型的半监督学习框架进行仿真分析中的主导失稳模式智能识别。VAT-MT 模型分别构造一个教师网络和学生网络, 通过对样本特征施加扰动后输入到两个网络中计算一致化损失来强化模型训练, 同时采用 VAT 计算最大扰动方向提升模型的性能。在中国电科院 36 节点系统和东北电网上进行算例研究, 结果表明, 所提出的方法能够极大降低样本的标注成本, 具有适应实际电网的能力。

关键词: 仿真数据分析; 主导失稳模式; 半监督学习; 均值教师; 虚拟对抗训练

0 引言

随着电网规模不断扩大, 电网公司每年需要进行大量的数字仿真辅助进行电力系统的规划、运行方式和控制决策的制定^[1]。随着仿真软件的优化和硬件水平的提高, 现阶段实际大电网的仿真计算速度有了巨大提升, 为调度中心进行批量仿真计算提

基金项目: 国家自然科学基金项目(U1866602)。

Project Supported by National Natural Science Foundation of China (U1866602).

供了可靠的技术支持,同时也产生了海量待分析的仿真数据,如果仍旧采用传统的人工分析方式效率极低。例如,国家电网调度中心每年需要集结上百人耗时数月进行仿真计算和仿真分析用以决定潮流运行方式和不同故障条件下的紧急控制策略。

电网仿真可以分为仿真计算和仿真数据分析两部分,仿真计算产生的海量数据呈现出维度高、冗余度大、稀疏、复杂时空关联等特点,使得仿真数据的分析难度越来越大^[2-3],以国家电网 50000 节点网架进行一次仿真计算为例,仿真涉及数百万参数,可输出变量高达百万个。而现有的分析方式主要通过人工进行,具有严重依赖专家经验、费时费力、分析误差难以控制、错漏现象日益增多等缺陷^[1]。近年来,大容量存储、高速计算等技术的飞速发展推动了深度学习(deep learning, DL)方法的飞跃进步,DL 的超强高维表征能力促进了其在图像识别^[4]、自然语言处理^[5]、推荐系统^[6]、医学影像处理^[7]等领域的广泛应用,DL 在这些领域的成功实践极大降低了人工成本、减轻了对专家经验的依赖。电网仿真数据的海量、高维、稀疏以及分析困难等特征给 DL 在电力仿真数据分析中的应用提供了契机,使得 DL 有望替代传统的人工分析方法,实现如图 1 所示的高效、准确和全面的智能化电网仿真数据分析。

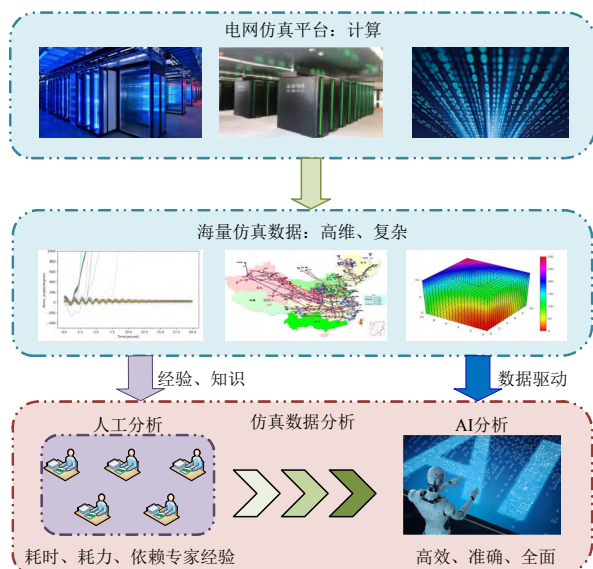


图1 电网仿真流程及人工分析与人工智能分析对比

Fig. 1 Power grid simulation process and comparison between manual analysis and AI analysis

根据我国最新的《电力系统安全稳定导则》(GB-38755-2019^[8]),我国电力系统稳定性可以分为功角失稳、电压稳定和频率稳定,根据扰动大小和

持续时间长短,又可以具体对每一种分类进行划分。在电网仿真数据分析过程中,一个重要的过程就是对依据预想故障集生成的暂稳计算数据进行稳定性分析以及失稳后的主导失稳模式(dominant instability mode, DIM)识别^[9],即确定失稳是由功角失稳还是电压失稳占主导,DIM 识别在离线制作紧急控制决策过程中具有很强的辅助作用,可以有效减少决策空间。然而,实际电网中功角失稳和电压失稳可能交织出现^[10],尽管现有一些理论判据和实用准则可以在一定程度上识别功角失稳和电压失稳^[10-12],但是这些方法的使用均要求负荷和振荡中心具有较强的电气联系^[13],难以涵盖所有的失稳情况,对于实际复杂大电网的应用效果也难以保证。

现有 DIM 识别方法的缺陷导致了现阶段仿真数据分析中通常采用人工依赖专家经验进行判断的方式,工作效率低、难以保证准确率。而 DL 具有超强的数据挖掘能力,可以有效避开 DIM 识别问题中复杂的物理机理分析过程,从原始的仿真数据中搜索目标相关的特征,通过对大量样本的学习强化模型表达能力,实现快速、准确、全面的判断。近几年已经有一些研究将 DL 方法应用到电力系统在线的暂态稳定评估^[14-16]、电压稳定评估^[17-18]中,然而这些方法都只关注了单一的功角失稳或者电压失稳,没有考虑两种失稳模式耦合的情况。

DL 的优良性能是建立在对大量有标注样本进行监督学习的基础之上,电网仿真数据的获取成本很低,一般设置较为全面的仿真初始条件即可获得海量的样本。然而,DIM 识别这一问题的标注成本是比较昂贵的,一些功角失稳与电压失稳现象交织出现的样本,往往需要通过多次切机/切负荷仿真才能确定其主导性,会大大增加标注样本的成本,以东北电网(千节点级)为例,需要数万个样本才能达到较高的判断准确率。为了降低模型对标注样本的依赖,常用的方法是半监督学习(semi-supervised learning, SSL)^[19],SSL 认为无标签样本也带有大量有助于分类的信息,模型融合了有标签样本和无标签样本共同优化模型。

近几年,基于 DL 的 SSL 方法发展迅猛,其关键在于如何挖掘无标注样本中对于指定的分类任务有用的信息,即如何构造一个适合无标注样本的训练目标,现在主要的研究思路是构造正则化来评估无标注样本的损失,包括采用熵正则化(伪标

签)^[20]以及一致化正则(consistency regularization, CR)^[21-23]的方法。CR 在局部平滑的假设下,认为对无标签的样本施加一定量的小扰动后不影响输出的结果。本文基于文献[24]提出的均值教师(mean teacher, MT)方法,分别构造一个教师网络和学生网络,教师网络为学生网络提供无标签样本的训练目标,在训练过程中,学生网络利用有标注样本的交叉熵损失和全体样本的 CR 进行训练和参数更新,教师网络则通过指数移动平均(exponential moving average, EMA)融合学生网络的参数进行更新。进一步分析发现,原始的 MT 算法中扰动的施加是随机的,导致模型不能很好利用无标注样本的信息,因此本文引入虚拟对抗训练(virtual adversarial training, VAT)^[23]进行最大扰动搜寻,即在一定范围内找到一个扰动向量使得模型的输出

分布发生最大的改变,最大扰动向量的引入,可以提升 CR 在训练中的作用。在 CEPRI-36 节点系统和东北电网上进行算例研究,结果表明,所提 VAT-MT 模型能够极大降低模型对标注样本的依赖, VAT 的引入也能提升 MT 模型的性能,同时具有适应实际大电网的能力。

1 基于 SSL 的 DIM 智能识别框架

本节以电力系统仿真数据中的主导失稳模式识别为背景,提出基于 SSL 的整个应用框架,并重点介绍样本生成与处理、用来进行 DIM 识别的卷积神经网络(convolutional neural networks, CNN)及其如何应用到电力系统暂稳仿真分析中,模型的整体框架和应用流程如图 2 所示。

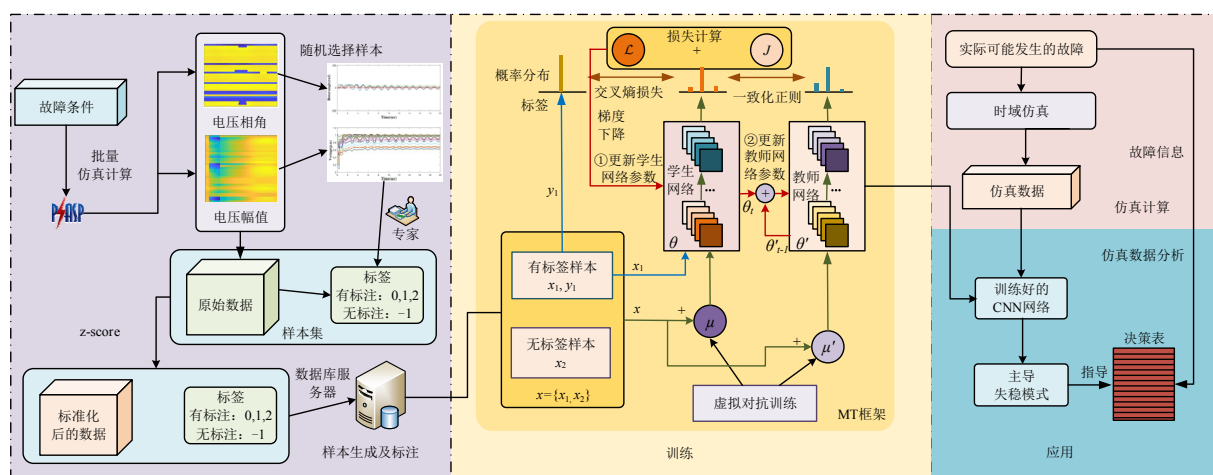


图 2 模型整体框架及应用流程图

Fig. 2 Overall framework and application flow chart of the model

1.1 DIM 样本集生成及处理

由于电压稳定与负荷类型紧密相关,因此 DIM 样本集的生成与暂态稳定评估不同。如果负荷采用恒阻抗模型,那么电力系统不会出现电压失稳^[25],因而在利用仿真生成样本的时候负荷应该采用恒阻抗与感应电动机结合的模式。本文采用中国电科院研发的 PSASP 软件批量生成 DIM 样本,时域仿真时间设为 20s,仿真过程中,通过改变初始潮流、故障线路、故障位置、故障持续时间以及电动机负荷比例,生成足够多的具有代表性的样本。

SSL 相对监督学习的优势是只需要少量的标注样本,因此在样本标注阶段,仅需随机选择少量的样本交由专家进行标注。专家在标注时通过观察电压幅值、相角和发电机功角曲线,并结合故障位置

等信息综合判断,这个过程严重依赖专家经验,专家进行样本标注的经验知识参考文献[8]。对于功角失稳和电压失稳交织的样本,为保证样本标注的准确性,常用系统失稳后施加强急控制策略来验证主导失稳模式,具体地,切除发电机能使得系统恢复稳定或失稳程度下降的为功角失稳,切除负荷能使得系统恢复稳定或失稳程度下降的为电压失稳。

文献[14,26]指出,故障发生的时候电压相角相比于功角变量(如功角、角速度)等响应要快,另外为了尽可能节省训练过程中对 GPU 的内存占用,提升训练速度,DL 网络选择电网中母线的电压幅值和相角作为输入。假设研究的电力系统有 N 条母线,模型输入特征的观测窗口从故障发生一直持续 T 秒,数据的采样频率设为 $f=100\text{Hz}$,即每半个工

频周期采样一次, 总共的采样点个数为 $s=Tf$ 。由于电压幅值和相角的数值可能相差很大, 因此输入模型前必须先对其进行 z -score 标准化, 用以消除量纲, 避免训练过程中数值不稳定。对于任意一个样本, 输入的电压相角和幅值矩阵分别为:

$$U = \begin{bmatrix} U_{1,1} & U_{1,2} & \cdots & U_{1,s} \\ U_{2,1} & U_{2,2} & \cdots & U_{2,s} \\ \vdots & \vdots & \ddots & \vdots \\ U_{N,1} & U_{N,2} & \cdots & U_{N,s} \end{bmatrix} \quad (1)$$

$$\theta = \begin{bmatrix} \theta_{1,1} & \theta_{1,2} & \cdots & \theta_{1,s} \\ \theta_{2,1} & \theta_{2,2} & \cdots & \theta_{2,s} \\ \vdots & \vdots & \ddots & \vdots \\ \theta_{N,1} & \theta_{N,2} & \cdots & \theta_{N,s} \end{bmatrix} \quad (2)$$

1.2 CNN 网络

本文提出的基于 VAT-MT 的 SSL 方法本质是一种 SSL 的训练框架, 其目标是训练一个性能良好的 DL 网络, VAT-MT 模型的原理和数学推导将在第 2 节重点讲解。方法的研究过程中以 CNN 作为主导失稳模式识别的 DL 网络模型, CNN 是由卷积层、池化层、批标准层以及全连接层构成的复杂网络, 其结构如图 3 所示。CNN 的核心部件是卷积层, 同时也是 CNN 特征提取的关键, 每一个卷积层包含多个滤波器, 滤波器的大小通常是固定的, 利用特征与滤波器之间的卷积计算可以过滤出每个滤波器想要提取的特征。通常滤波器的大小远小于输入特征的大小, 因而可以通过稀疏连接和参数共享的方式减少模型参数, 减轻因为神经元数量过多带来的过拟合风险。




图 3 CNN 网络结构

Fig. 3 Network structure of CNN

在模型训练阶段, 采用 Kaiming 分布随机初始化网络权重^[27], 并选用 Adam 作为优化器^[28], 初始学习率设为 0.001, 并在 100 个 epoch 后以指数形式进行下降。样本集中训练集、验证集和测试集的比例为 8:1:1, 样本集中有标注样本的标签分别为: 0-稳定、1-功角失稳和 2-电压失稳, 无标注样本的标签全部设为-1, CNN 网络的参数更新由 VAT-MT 控制。

1.3 模型应用

要想获得一个性能好的 CNN 网络, 需要不断尝试更改网络和模型的超参数, 最终选择一个合适的网络作为待应用的深度网络。在应用阶段, 首先需要根据实际大电网中可能发生的故障集进行时域仿真, 进而得到仿真数据, 然后将得到的仿真数据经过 z -score 标准化, 即可输入训练好的 CNN 网络中得到主导失稳模式, 为后续制定紧急控制策略表提供指导。

2 融合 VAT 和 MT 的 SSL 模型

本文所用的 MT 模型是一种 SSL 框架, 其核心借鉴了知识蒸馏模型中的教师网络和学生网络, 通过向输入特征施加扰动并利用教师网络与学生网络的输出, 构造 CR 作为训练过程中损失函数的一部分, MT 模型能够挖掘出无标注样本中对分类目标有用的特征信息。由于 MT 模型中学生网络和教师网络结构完全一致, 因此可以用学生网络和学生网络的历史参数实时更新教师模型, 是教师模型参数能够更新的关键。为进一步提升模型性能, 本文研究发现, MT 模型中添加随机噪声来获取 CR 损失的方式不能很好地利用无标注样本的信息, 为解决这一问题, 本文采用 VAT 的方法搜寻最大扰动方向, 并以此作为 MT 模型的扰动大小。

2.1 一致化正则

SSL 的重点是如何衡量无标注样本的信息, 现有基于 DL 的 SSL 模型通常是利用 CR 来实现的。深度 SSL 中构造 CR 的目的是为了给无标注样本提供一个高效合理的训练方向, 以便模型能够从无标注样本中挖掘有助于分类目标的信息, 从而滤除对分类有害的信息。CR 的主要思想在于 SSL 中的局部平滑假设, 即认为对样本的输入特征施加小扰动后应该不影响 CNN 模型输出的分布。具体地, MT 模型的 CR 构造方法为: 样本的输入特征施加扰动或者噪声(数值远小于特征的数值)后, 分别经由学生网络和教师网络得到输出结果, 然后学生网络的输出 $f(x, \theta, \mu)$ 和教师网络的输出 $f(x, \theta', \mu')$ 分布的差异作为一致化损失并参与到反向传播当中。其中, x 为输入特征, θ 和 θ' 分别为学生网络和教师网络的参数, μ 和 μ' 分别是输入两个网络的噪声大小。施加噪声让原始的特征发生了微弱的偏移, 但是 CR 让模型学习到在这微弱偏移附近的样本应都是属于同一类, 这个过程相当于让具有相似特征的样本

聚合到一起, 是一种泛化的聚类思想。

2.2 MT 模型数学推导

MT 只是一个 SSL 框架, 适应于任意一个 DL 网络, 其结构如图 2 中间部分所示, 训练过程中有标注样本的损失一方面与监督学习一致, 采用交叉熵损失函数; 另一方面所有样本计算一致化损失:

$$J(x, \theta, \mu, \theta', \mu') = \mathbb{E}[f(x, \theta, \mu), f'(x, \theta', \mu')] \quad (3)$$

式中 \mathbb{E} 为散度函数, 可以用来计算两个分布之间的差异, 通常为 KL 散度或均方差。训练过程中的损失值可以表示为

$$L = \mathcal{L}[f(x_1, \theta), y_1] + J(x, \theta, \mu, \theta', \mu') \quad (4)$$

式中: x_1 为有标注样本的输入特征; y_1 为对应的标签; x_2 为无标注样本的输入特征; $x = \{x_1, x_2\}$ 表示全体样本; \mathcal{L} 为交叉熵损失函数。需要说明, 在本文后续算例中, 施加的噪声的值为 0.01 倍的标准高斯噪声(服从均值为 0, 标准差为 1 的正态分布), 这个噪声大小在 $10^{-3} \sim 10^{-2}$ 这个量级, 远小于输入特征的数值大小, 因此不会影响数据的标签。式(4)的计算结果通过反向传播用于更新学生网络的参数 α (神经网络中的权重、偏置等); 对于教师模型的参数 θ' , 采用 EMA 进行更新:

$$\theta'_t = \alpha \theta'_{t-1} + (1 - \alpha) \theta_t \quad (5)$$

式中: θ'_t 和 θ_t 分别为教师模型和学生模型训练中第 t 个 step 的参数; α 为权重超参数。训练前期, 模型并不稳定, 训练主要依靠有标注样本, 学生网络的性能应该比教师网络好, 因此 α 应该偏小; 到了训练的后期, 模型趋于稳定, 教师网络的性能逐渐提高并优于学生网络, 因此 α 应该趋于 1, α 的表达式为

$$\alpha = \min\{1 - e^{-t/100}, \alpha_{\max}\} \quad (6)$$

式中 α_{\max} 为设定的最大权重。

2.3 基于 VAT 的最大扰动搜寻

如 2.1 节所述, 模型应该能够适应微小输入的改变。因此在训练过程中, 需要向样本的输入特征中加入扰动, 使得模型具备抵御干扰的能力, 同时可以强化决策边界, 使得决策边界附近的样本分布变得稀疏, 也就是加强了模型分类能力。一种最优的对抗训练方法就是寻找一个因小扰动导致模型输出产生最大变化的方向, 称为最大扰动方向, 在这个方向加上扰动 μ 用于训练相对于施加随机噪声具有更好的效果, 可以充分挖掘样本间的相似信息。本文通过 VAT 搜寻最大扰动方向:

$$\Delta_{KL}(\mu, x, \theta) = K_L[p(y|x, \theta) \| p(y|x + \mu, \theta)] \quad (7)$$

式中 $p(y|x)$ 是模型的输出, 通过 KL 散度计算施加扰动后模型输出的差异, 进一步, 需要搜寻的扰动为:

$$\mu = \arg \max \{\Delta_{KL}(\mu, x, \theta); \|\mu\|_2 \leq \varepsilon\} \quad (8)$$

式中 $\|\mu\|_2 \leq \varepsilon$ 是限制扰动最大值的 L_2 正则。求解最优扰动 μ 的过程本质是一个优化过程, 沿用对抗训练中的优化求解过程, 首先给定一个初始随机扰动 μ_0 , 然后通过迭代让扰动 μ 的搜寻沿着梯度提升的方向进行, 计算当前样本 x 在第 t 次迭代时关于施加扰动前后输出差异的梯度:

$$g_t = \nabla_x K_L[p(y|x; \theta), p(y|x + \mu_t; \theta)] \quad (9)$$

进一步:

$$\mu_{t+1} = \varepsilon \frac{g_t}{\|g_t\|_2} \quad (10)$$

通过多次迭代式(9)和(10), 在达到迭代次数(一般为 2~3 次)时, 即可获得需要的最佳扰动 μ 。

图 4 是 VAT 的原理示意图, 实心圆表示不同的样本, 用蓝色和红色区分不同的类别, 原始分类边界用绿色虚线表示, 经过 VAT 后的分类边界用深橙色实线表示, 图中展示了 3 个样本搜寻最大扰动的结果, 对于处在分类边界附近的样本(容易误判的样本), 其扰动量的值 $\|\mu\|$ 小于 ε , 相当于寻找一个从样本出发, 垂直指向分类边界的向量, 这个向量的模是样本跟分类边界之间距离的最小值; 对于远离分类边界的样本, 搜寻的向量的模为 ε 。以图中的一个蓝色样本为例说明 VAT 相对于随机扰动的优势, 当施加的扰动大小为 μ_1 时, 模型的输出分布不会发生太大改变, 因为其扰动后的值仍在蓝色分类中, 但是当施加的扰动大小为 μ 时, 模型会出现误判, 认为其属于红色类别, 进一步通过 CR 就可以让模型具有抵抗这种能改变模型输出分布的扰动的能力。整体而言就是让模型分类边界附近的样本变

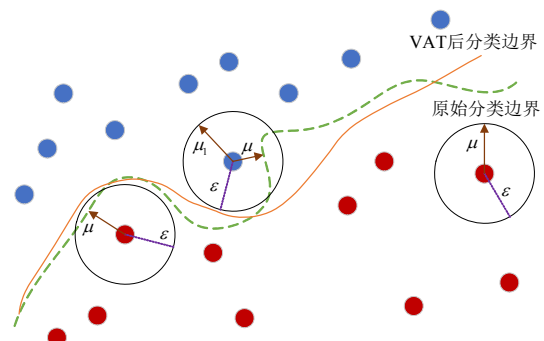


图 4 VAT 原理示意图

Fig. 4 Schematic diagram of VAT

得稀疏,边界处样本分布更加稀疏,模型能更好的抵抗输入扰动。

2.4 VAT-MT 模型训练算法

综合 2.2 节中 MT 算法和 2.3 节的 VAT 扰动优化算法,本文提出 VAT-MT 模型的训练过程,如图 5 所示。

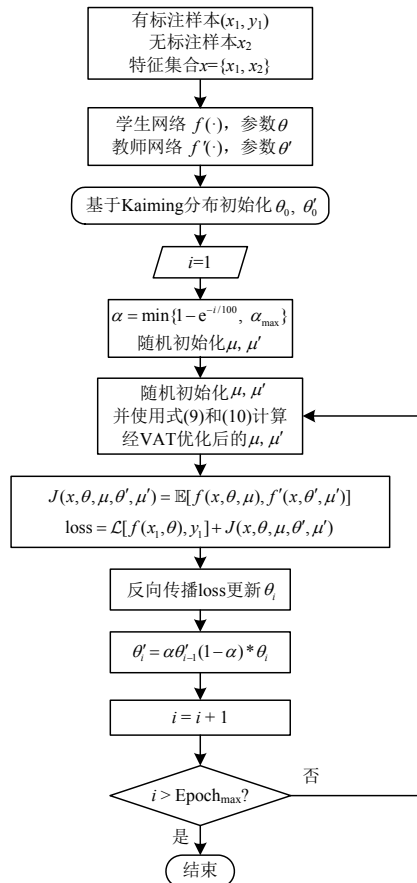


图 5 VAT-MT 训练流程图

Fig. 5 Training flow chart of VAT-MT

3 算例研究

为了验证所提出的 SSL 模型应用的有效性,本文在 CEPRI-36 节点系统和中国东北实际电网进行了算例研究。其中 DL 网络以及 VAT-MT 模型均基于 PyTorch 搭建,算例测试所用的硬件平台为: Intel Core(TM) i9-10900K @ 3.70GHz CPU, 128GB RAM, NVIDIA RTX2080 Super GPU。

3.1 CEPRI-36 节点系统

3.1.1 样本生成

CEPRI-36 节点系统包含 8 个发电机组、26 条交流母线、36 个母线节点、3 台三绕组变压器以及 10 个负荷节点,其单线图如图 6 所示。

负荷模型由恒阻抗与电动机复合构成,其比例可调,为了模拟实际中不同的工况,算例选择 3 种

不同的初始潮流。仿真过程中的故障均设置为三相金属性短路接地,故障遍历所有的交流线路,可调节的故障条件为故障位置和故障持续时间。样本生成中的具体设置如表 2 所示,总共生成 7800 个样本,其中稳定样本 2553 个,功角失稳样本 1863 个,电压失稳样本 3384 个。需要注意,本文的研究背景是仿真数据分析,因此可以选择相对较长的观测时间窗口,本文选择故障后 2s 的信息作为模型的输入特征,即 $s=200$, $U \in \mathbb{R}^{36 \times 200}$, $\theta \in \mathbb{R}^{36 \times 200}$ 。

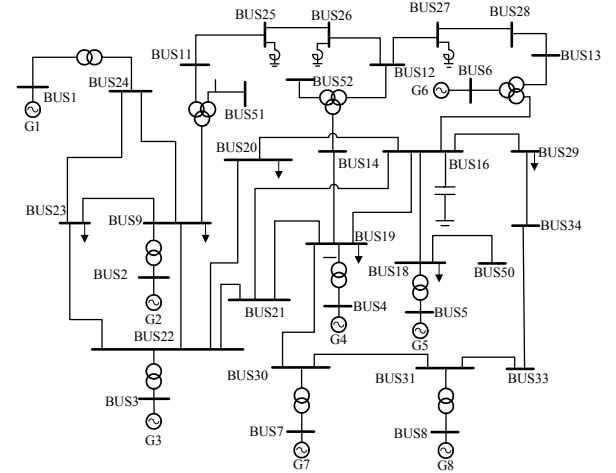


图 6 CEPRI-36 节点单线图

Fig. 6 Single-line diagram of CEPRI-36 bus system

表 2 CEPRI-36 节点系统样本集生成方案

Table 2 Configurations of the dataset generation on CEPRI-36 bus system

条件	具体设置	类别
潮流水平	90%, 100%, 110%	3
负荷电动机比例	50%, 60%, 70%, 80%, 90%	5
故障线路	所有交流线	26
故障位置	2%, 20%, 50%, 80%, 98%	5
故障持续时间	0.05s, 0.15s, 0.25s, 0.3s	4
故障类型	三相金属性短路接地	1

3.1.2 模型训练和测试

算例所用的深度 CNN 网络主要包括三层卷积层、三层最大值池化层以及三层全连接层,具体结构、参数以及激活函数使用情况如图 7 所示。

首先,为了说明深度 CNN 网络在解决 DIM 识别这类复杂分类问题时候的优势,本文先进行了多种机器学习方法与本文所用的 CNN 网络进行监督学习的对比,并选取总样本的 80%作为训练集,20%作为测试集。选取的对比机器学习方法有:支持向量机(support vector machine, SVM)、决策树(decision tree, DT)、K 近邻(K-nearest neighbor, KNN)和随机森林(random forest, RF)。不同机器学习方法准




图 7 基于 CNN 的主导失稳模式识别网络结构

Fig. 7 DIM identification network structure based on CNN

准确率对比结果如表 3 所示，测试结果表明基于 DL 的 CNN 网络具有最好的判断准确率。

表 3 CEPRI-36 节点系统机器学习方法准确率对比
Table 3 Accuracy comparison of different machine learning methods on CEPRI-36 system

方法	准确率/%
CNN	96.50
SVM	94.70
DT	93.90
KNN	93.70
RF	95.10

在 MT 模型超参数寻优过程中，应重点关注 α_{\max} ，其值决定了教师网络和学生网络在什么时候无标签样本成为更新网络参数的重点，本例设置多个 α_{\max} 参数并寻找其表现相对较好的值。为了验证提出的 VAT-MT 模型的有效性，本文以只利用有标签样本训练的 CNN 模型作为对比，具体测试结果如图 8 所示。可以看出，在各种情况下(不同 α_{\max} 和不同标注样本比例)半监督学习的方法都好于纯监督学习方法；采用 VAT-MT 的 SSL 模型只利用少量标注样本即可较大提升 CNN 网络的判断准确率，




图 8 CEPRI-36 节点系统对比测试结果

Fig. 8 Comparison test results of CEPRI-36 bus system

仅使用 5%有标注的训练集样本(312 个)即可达到将近 96%的判断准确率，而纯监督学习则需要 50%的标注样本才能得到同等效果；且在标注样本比例较小的情况下，VAT-MT 模型提升的效果更明显。此外，从各种标注样本比例下不同 α_{\max} 的结果可以看出当其值取 0.9 时，模型的判断准确率最高。为进一步说明模型训练的收敛性能，图 9 展示了仅有 1% 标准样本时，VAT-MT 模型的一致化损失、交叉熵分类损失以及两个网络在验证集上的准确率。




图 9 训练过程中损失函数和准确率变化曲线

Fig. 9 Loss and accuracy curves during training

进一步，为了验证 VAT 有助于提升模型性能，测试模型带 VAT 与否对性能的影响，结果如图 10 所示($\alpha_{\max}=0.9$)。可以看出，引入 VAT 后，MT 模型的效果有所提升，在采用极少样本训练的时候(训练集中标注样本比例小于 10%)，VAT 提升了 MT 模型近 2%的判断准确率，在 10%标注比例的时候即可达到 96%的准确率，达到不带 VAT 的 MT 模型在训练集标注样本率 50%时候的取得的结果，提升效果明显。因此，VAT 使得 MT 模型更加充分的利用了样本间的相似性的信息。

为了展示 VAT 方法在训练过程中对 MT 模型性能的优化，绘制了训练过程中 MT 模型与 VAT-MT

模型的学生网络与教师网络的测试集准确率(1%标注样本),结果如图11所示,可以看出,VAT可以明显提高MT模型的判断准确率。




图10 带有VAT对MT模型的效果影响

Fig. 10 Effects of VAT on MT model




图11 VAT-MT模型与MT模型的准确率曲线

Fig. 11 Accuracy curves of VAT-MT model and MT model

3.1.3 结果可视化

为了验证经由VAT-MT模型采用少量标注样本训练的CNN网络的分类性能,将测试集样本经过教师网络第一层全连接层后的输出结果通过t分布随机近邻嵌入(t-distributed stochastic neighbor embedding, t-SNE)^[29]降维到二维平面,降维后的结果可以直观的反映不同样本之间的相似程度,通常相似程度越高的样本,在二维平面上距离越近。

图12展示VAT-MT模型仅使用2%有标注样本训练的CNN模型在测试集上的t-SNE结果,图中各个样本点很明显被分为了3簇,反映出训练得到的VAT-MT模型有效学到了3种类别之间的差异。

3.1.4 模型泛化性

现阶段深度学习模型存在的一个主要问题是模型泛化性能不够,其中最重要和突出的方面是难以适应电网拓扑的变化,然而实际中电力系统很可




图12 2%标注样本训练得到的模型的t-SNE结果

Fig. 12 T-SNE results of the model trained by 2% labeled samples

能会因为检修和继电保护动作等情况导致出现一条线路断开运行。电网拓扑的改变导致模型泛化性能下降严重的根本原因是新拓扑下的样本的分布与训练样本不同,即电网拓扑改变本质上改变的是样本的分布,如果提供足够多拓扑下的样本混合到一起,那么新的样本集是服从同一个分布的,再结合半监督学习方法,仍然只需要少量的有标注样本即可实现较高的准确率。

为了验证上述说法,本文补充生成了4212个在 $N-1$ 拓扑下的少量样本并结合之前生成的基本拓扑下的样本混合在一起进行半监督学习,用以验证半监督学习模型在适用电网拓扑改变情况下的优势。测试结果如图13所示,从结果看出,融合了 $N-1$ 样本的新数据集相对于基准数据集准确率并没有明显下降,因此,可以认为本文提出的半监督学习方法可以在一定程度上解决电网拓扑改变的问题。




图13 模型泛化性能测试结果

Fig. 13 Test results of model generalization

3.2 东北电网

为了验证模型适应实际大电网的能力,本文在

中国东北电网上测试 VAT-MT 性能, 东北电网包含 2131 条母线, 1748 条传输线以及 223 台同步发电机。东北电网样本数据集的生成与 CEPRI-36 节点系统类似, 所不同的是初始潮流选择了实际运行中典型的 4 种潮流工况, 故障线路只考虑 500kV 线路, 具体生成方案如表 4 所示, 最终总共生成了 30048 个样本。

表 4 东北电网 DIM 样本集生成方案
Table 4 Configurations of the DIM dataset generation on Northeast China Power Grid

条件	具体设置	类别
潮流水平	4 种典型潮流工况	4
负荷电动机比例	60%, 75%, 90%	3
故障线路	所有 500kV 线路	313
故障位置	2%, 50%	2
故障持续时间	0.1s, 0.2s, 0.25s, 0.3s	4
故障类型	三相金属性短路接地	1

模型训练与测试过程与 CEPRI-36 节点系统类似, 但是输入特征只采用 500kV 母线的电压幅值和相角。首先进行不同机器学习方法的有监督学习验证 CNN 网络能够取得相对于非 DL 方法有更好的性能, 其结果如表 5 所示。

表 5 东北电网机器学习方法准确率对比
Table 5 Accuracy comparison of different machine learning methods on Northeast China Power Grid

方法	准确率/%
CNN	96.10
SVM	93.70
DT	92.70
KNN	91.50
RF	95.50

此外, 本文选取不同 α_{\max} 参数测试其对 VAT-MT 模型的影响, 并且以监督学习作为对照实验, 结果如图 14 所示。从图 14 可以看出, 在实际的东北电网中, 本文提出的 VAT-MT 模型能够利用较少的样本极大提高模型的判断准确率, 以仅利用训练集 0.5%(150 个)的有标注样本进行训练为例, 纯监督学习仅能取得 82%左右的准确率, 而 VAT-MT 模型可以达到 88%以上。随着训练集中有标注样本的增加, 采用的 VAT-MT 模型利用训练集中 20%的有标注样本训练的 CNN 网络可以取得 96%以上的准确率, 这是监督学习利用训练集中所有标注样本进行训练才能取得的结果。

同样, 为了体现 VAT-MT 模型的训练有效性和收敛性, 图 15 给出了只使用 1%有标注样本的




图 14 东北电网 MT 模型测试结果

Fig. 14 Test results of MT model on Northeast China Power Grid




图 15 东北电网训练过程中损失函数和准确率变化曲线

Fig. 15 Loss and accuracy curves during training on Northeast China Power Grid

VAT-MT 模型在训练过程中的一致化损失、交叉熵分类损失和两个网络的准确率变化曲线。

同样, 测试 MT 模型是否采用 VAT 对模型性能的影响, 结果如图 16 所示($\alpha_{\max}=0.9$), 可以发现 VAT 能够明显地提升 MT 模型的性能, 在各种标注样本比例下基本能提升 2%的准确率, 说明 VAT 也能适应实际大电网中 MT 模型。

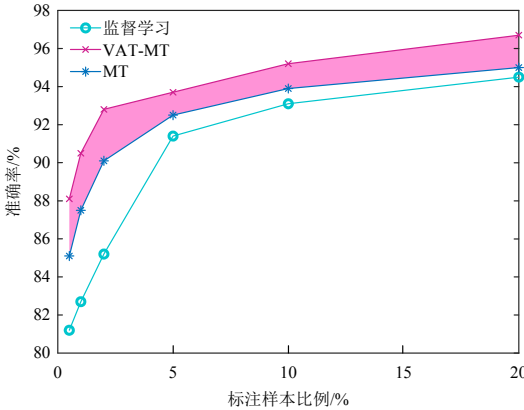


图 16 东北电网算例中 VAT 对 MT 模型的效果影响

Fig. 16 Effect of VAT on MT model in Northeast China Power Grid

为了验证 VAT-MT 模型的特征学习能力,采用同 3.1.3 节一样的 t-SNE 算法对教师网络提取到的特征进行可视化。这里使用的训练好的教师网络是只采用 1%(300 个)有标注样本通过 VAT-MT 模型训练得到的,具体结果如图 17 示。从图中可以看出,通过 VAT-MT 模型,在东北电网中仅利用 1%的有标注样本训练得到的教师网络即能有较好的特征提取能力。




图 17 东北电网用 1%标注样本训练的模型的 t-SNE 结果
Fig. 17 T-SNE results of the model trained by 1% labeled samples on Northeast China Power Grid

4 结论与展望

本文从降低 DL 的标注成本角度出发,将 SSL 方法引入电力系统仿真数据分析中,提出一种融合虚拟对抗训练和均值教师模型的主导失稳模式识别半监督学习框架。为了验证所提方法的有效性,本文在 CEPRI-36 节点系统和我国东北电网上进行了算例测试。

1) 大电网仿真会产生大量的样本,对仿真数据进行主导失稳模式分析可以为制定实际电网的紧急控制决策表提供指导,采用 DL 等人工智能分析的方法能够降低对人力的投入和专家经验的依赖,做到快速、准确、全面的分析。

2) 基于监督学习的 CNN 网络的性能依赖大量的标注样本,而大电网的主导失稳模式往往很难判断,因此标注困难,本文引入的 SSL 方法可以显著降低 CNN 网络的标注成本,降低其在电网仿真分析中的难度。

3) 本文利用 MT 模型构造 SSL 中的 CR,使得模型能够挖掘无标注样本中对分类有用的信息,同时通过 VAT 搜寻使得模型输出分布改变最大的方向来强化模型的训练。

4) 算例测试表明,MT 模型能够利用极少的有

标注样本即可取得较高的主导失稳模式识别准确率,且在训练集中标注样本比例越低时提升效果越明显;此外,VAT 也能显著提升 MT 模型的性能。

现阶段我国电力系统正处在向高比例新能源接入的“新型”电力系统的转化过程中。近年来,有研究表明,“双高”电力系统中存在的电力电子设备引起的稳定性问题^[30-31],在后续研究中,作者将以西北电网为例,探索其中可能存在的新型失稳模式。

参考文献

- [1] TANG Yong, HUANG Yanhao, WANG Hongzhi, et al. Framework for artificial intelligence analysis in large-scale power grids based on digital simulation[J]. CSEE Journal of Power and Energy Systems, 2018, 4(4): 459-468.
- [2] 黄彦浩,于之虹,谢昶,等. 电力大数据技术与电力系统仿真计算结合问题研究[J]. 中国电机工程学报, 2015, 35(1): 13-22.
HUANG Yanhao, YU Zhihong, XIE Chang, et al. Study on the application of electric power big data technology in Power system simulation[J]. Proceedings of the CSEE, 2015, 35(1): 13-22(in Chinese).
- [3] 田芳,黄彦浩,史东宇,等. 电力系统仿真分析技术的发展趋势[J]. 中国电机工程学报, 2014, 34(13): 2151-2163.
TIAN Fang, HUANG Yanhao, SHI Dongyu, et al. Developing trend of power system simulation and analysis technology[J]. Proceedings of the CSEE, 2014, 34(13): 2151-2163(in Chinese).
- [4] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[C]//Proceedings of the 25th International Conference on Neural Information Processing Systems. Lake Tahoe: NIPS, 2012: 1097-1105.
- [5] COLLOBERT R, WESTON J. A unified architecture for natural language processing: deep neural networks with multitask learning[C]//Proceedings of the 25th International Conference on Machine Learning. Helsinki: ACM, 2008: 160-167.
- [6] CHENG H T, KOC L, HARMSSEN J, et al. Wide & deep learning for recommender systems[C]//Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. Boston: ACM, 2016: 7-10.
- [7] SHEN Dinggang, WU Guorong, SUK H I. Deep learning in medical image analysis[J]. Annual Review of

- Biomedical Engineering, 2017, 19: 221-248.
- [8] 国家市场监督管理总局, 国家标准化管理委员会. GB 38755—2019 电力系统安全稳定导则[S]. 北京: 中国标准出版社, 2019.
- State Administration for Market Regulation, Standardization Administration. GB 38755—2019 Code on security and stability for power system[S]. Beijing: Standards Press of China, 2019(in Chinese).
- [9] 石重托, 姚伟, 黄彦浩, 等. 基于 SE-CNN 和仿真数据的电力系统主导失稳模式智能识别[J/OL]. 中国电机工程学报, 2021[2021-11-08]. <http://kns.cnki.net/kcms/detail/11.2107.TM.20211105.1639.046.html>.
- SHI Zhongtuo, YAO Wei, HUANG Yanhao, et al. Power system dominant instability mode identification based on convolutional neural networks with squeeze and excitation block and simulation data[J/OL]. Proceedings of the CSEE, 2021[2021-11-08]. <http://kns.cnki.net/kcms/detail/11.2107.TM.20211105.1639.046.html>(in Chinese).
- [10] 吴为, 汤涌, 孙东华, 等. 电力系统暂态功角失稳与暂态电压失稳的主导性识别[J]. 中国电机工程学报, 2014, 34(31): 5610-5617.
- WU Wei, TANG Yong, SUN Donghua, et al. The recognition of principal mode between rotor angle instability and transient voltage instability[J]. Proceedings of the CSEE, 2014, 34(31): 5610-5617(in Chinese).
- [11] 汤涌, 林伟芳, 孙东华, 等. 基于戴维南等值跟踪的电压失稳和功角失稳的判别方法[J]. 中国电机工程学报, 2009, 29(25): 1-6.
- TANG Yong, LIN Weifang, SUN Donghua, et al. Method identifying voltage instability and angle instability based on tracking Thevenin equivalent parameters[J]. Proceedings of the CSEE, 2009, 29(25): 1-6(in Chinese).
- [12] 侯俊贤, 韩民晓, 董毅峰, 等. 基于振荡中心和电压形态的暂态功角失稳和电压失稳判断方法[J]. 电网技术, 2016, 40(5): 1509-1515.
- HOU Junxian, HAN Minxiao, DONG Yifeng, et al. Transient angle instability and voltage instability identification method based on oscillation center and voltage curve characteristic[J]. Power System Technology, 2016, 40(5): 1509-1515(in Chinese).
- [13] 黎晓, 刘崇茹, 辛蜀骏, 等. 暂态功角稳定与暂态电压稳定的耦合机理分析与耦合强度评估指标[J]. 中国电机工程学报, 2021, 41(15): 5091-5106.
- LI Xiao, LIU Chongru, XIN Shujun, et al. Coupling mechanism analysis and coupling strength evaluation index of transient power angle stability and transient voltage stability[J]. Proceedings of the CSEE, 2021, 41(15): 5091-5106(in Chinese).
- [14] SHI Zhongtuo, YAO Wei, ZENG Linggang, et al. Convolutional neural network-based power system transient stability assessment and instability mode prediction[J]. Applied Energy, 2020, 263: 114586.
- [15] GUPTA A, GURRALA G, SASTRY P S. An online power system stability monitoring system using convolutional neural networks[J]. IEEE Transactions on Power Systems, 2018, 34(2): 864-872.
- [16] 王铮澄, 周艳真, 郭庆来, 等. 考虑电力系统拓扑变化的消息传递图神经网络暂态稳定评估[J]. 中国电机工程学报, 2021, 41(7): 2341-2349.
- WANG Zhengcheng, ZHOU Yanzhen, GUO Qinglai, et al. Transient stability assessment of power system considering topological change: a message passing neural network-based approach[J]. Proceedings of the CSEE, 2021, 41(7): 2341-2349(in Chinese).
- [17] WANG Guoteng, ZHANG Zheren, BIAN Zhipeng, et al. A short-term voltage stability online prediction method based on graph convolutional networks and long short-term memory networks[J]. International Journal of Electrical Power & Energy Systems, 2021, 127: 106647.
- [18] ZHANG Yuchen, XU Yan, ZHANG Rui, et al. A missing-data tolerant method for data-driven short-term voltage stability assessment of power systems[J]. IEEE Transactions on Smart Grid, 2019, 10(5): 5663-5674.
- [19] CHAPELLE O, SCHOLKOPF B, ZIEN A. Semi-supervised learning(chapelle, o. et al., eds.; 2006)[J]. IEEE Transactions on Neural Networks, 2009, 20(3): 542.
- [20] LEE D H. Pseudo-label: the simple and efficient semi-supervised learning method for deep neural networks[C]// Proceedings of Work Shop on Challenges in Representation Learning. Atlanta: ICML, 2013.
- [21] RASMUS A, VALPOLA H, HONKALA M, et al. Semi-supervised learning with Ladder networks[C]// Proceedings of the 28th International Conference on Neural Information Processing Systems. Montreal: NIPS, 2015: 3546-3554.
- [22] LAINE S, AILA T. Temporal ensembling for semi-supervised learning[C]// Proceedings of the 5th International Conference on Learning Representations. Toulon: OpenReview.net, 2017.
- [23] MIYATO T, MAEDA S, KOYAMA M, et al. Virtual adversarial training: a regularization method for supervised and semi-supervised learning[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(8): 1979-1993.

- [24] TARVAINEN A, VALPOLA H. Mean teachers are better role models: weight-averaged consistency targets improve semi-supervised deep learning results[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach: NIPS, 2017.
- [25] LOF P A, SMED T, ANDERSSON G, et al. Fast calculation of a voltage stability index[J]. IEEE Transactions on Power Systems, 1992, 7(1): 54-64.
- [26] RAJAPAKSE A D, GOMEZ F, NANAYAKKARA K, et al. Rotor angle instability prediction using post-disturbance voltage trajectories[J]. IEEE Transactions on Power Systems, 2010, 25(2): 947-956.
- [27] HE Kaiming, ZHANG Xiangyu, REN Shaoqing, et al. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification[C]//Proceedings of 2015 IEEE International Conference on Computer Vision. Santiago: IEEE, 2015: 1026-1034.
- [28] KINGMA D P, BA J. Adam: a method for stochastic optimization[C]//Proceedings of the 3rd International Conference on Learning Representations. San Diego: ICLR, 2015.
- [29] VAN DER MAATEN L, HINTON G. Visualizing data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9(11): 2579-2605.
- [30] 谢小荣, 贺静波, 毛航银, 等. “双高”电力系统稳定性的新问题及分类探讨[J]. 中国电机工程学报, 2021, 41(2): 461-475.
- XIE Xiaorong, HE Jingbo, MAO Hangyin, et al. New issues and classification of power system stability with high shares of renewables and power electronics[J]. Proceedings of the CSEE, 2021, 41(2): 461-475(in Chinese).
- [31] HATZIARGYRIOU N, MILANOVIC J, RAHMANN C, et al. Definition and classification of power system stability -revisited & extended[J]. IEEE Transactions on Power Systems, 2021, 36(4): 3271-3281.



张润丰

收稿日期: 2021-07-21。

作者简介:

张润丰(1998), 男, 硕士研究生, 研究方向为人工智能在电力系统稳定分析中的应用, runfeng_zhang@hust.edu.cn;

*通信作者: 姚伟(1983), 男, 博士, 教授, 研究方向为高比例新能源电网稳定分析与控制、新一代电力能源人工智能技术及应用、交直流混联电网稳定分析与控制, w.yao@hust.edu.cn;

石重托(1997), 男, 博士研究生, 研究方向为人工智能在电力系统稳定分析与控制中的应用, zt_shi@hust.edu.cn;

汤涌(1959), 男, 博士, 教授级高级工程师, 博士生导师, 研究方向为电力系统仿真与分析、电力系统稳定与控制, tangyong@epri.sgcc.com.cn;

文劲宇(1970), 男, 教授, 博士生导师, 主要研究方向包括电力系统规划运行与控制、储能与新能源并网、直流输电与直流电网等, jinyu.wen@hust.edu.cn。

(责任编辑 邱丽萍)

Semi-supervised Learning Framework of Dominant Instability Mode Identification via Fusion of Virtual Adversarial Training and Mean Teacher Model

ZHANG Runfeng¹, YAO Wei^{1*}, SHI Zhongtuo¹, TANG Yong², WEN Jinyu¹

(1. State Key Laboratory of Advanced Electromagnetic Engineering and Technology (School of Electrical and Electronic Engineering, Huazhong University of Science and Technology); 2. China Electric Power Research Institute)

KEY WORDS: simulation data analysis; dominant instability mode; semi-supervised learning; mean teacher; virtual adversarial training

Power grid simulation is of great significance to power system planning, operating, and control decision-making. It is an important step in simulation calculation to analyze the stability of power system and the dominant instability mode (DIM) according to the massive simulation data, so as to provide supports for the subsequent formulation of emergency control decisions.

In this paper, deep learning is used to overcome the problem that traditional methods are difficult to effectively distinguish power angle instability and voltage instability in the actual power grid. In order to reduce the dependence of the deep neural networks on labeled samples, this paper proposes a semi-supervised learning framework based on mean teacher (MT) with virtual adversarial training (VAT) model for the intelligent identification of DIM in simulation analysis. VAT-MT model constructs a teacher network and a student network, respectively. The model training is enhanced by applying small disturbance to the features of all samples, and then input into the two networks to calculate the consistency loss:

$$J(x, \theta, \mu, \theta', \mu') = \mathbb{E}[f(x, \theta, \mu), f'(x, \theta', \mu')] \quad (1)$$

where x is the sample features, θ and θ' are the parameters of the student network and teacher network,

respectively. μ and μ' are the noise of the two networks. Then, combined with the cross-entropy loss of the label samples (features: x_1 , label: y_1), the overall loss function is decided by the following formula:

$$L = L[f(x_1, \theta), y_1] + J(x, \theta, \mu, \theta', \mu') \quad (2)$$

At the same time, the maximum disturbance direction is calculated by VAT to improve the performance of the model:

$$\Delta_{KL}(\mu, x, \theta) = KL[p(y|x, \theta) || p(y|x + \mu, \theta)] \quad (3)$$

where $p(y|x)$ is the output of the deep network, and the difference of model output after disturbance is applied is calculated through KL divergence. Further, the disturbance to be searched is:

$$\mu = \arg \max \{\Delta_{KL}(\mu, x, \theta); \|\mu\|_2 \leq \varepsilon\} \quad (4)$$

This paper takes convolutional neural networks as the deep neural networks to be applied, and the overall application process is shown in Fig. 1. Case studies are conducted on the China Electric Power Research Institute 36-bus system and Northeast China Power Grid. The results show that the proposed method can effectively reduce the labeling cost, and has the ability to adapt to the actual power grid.

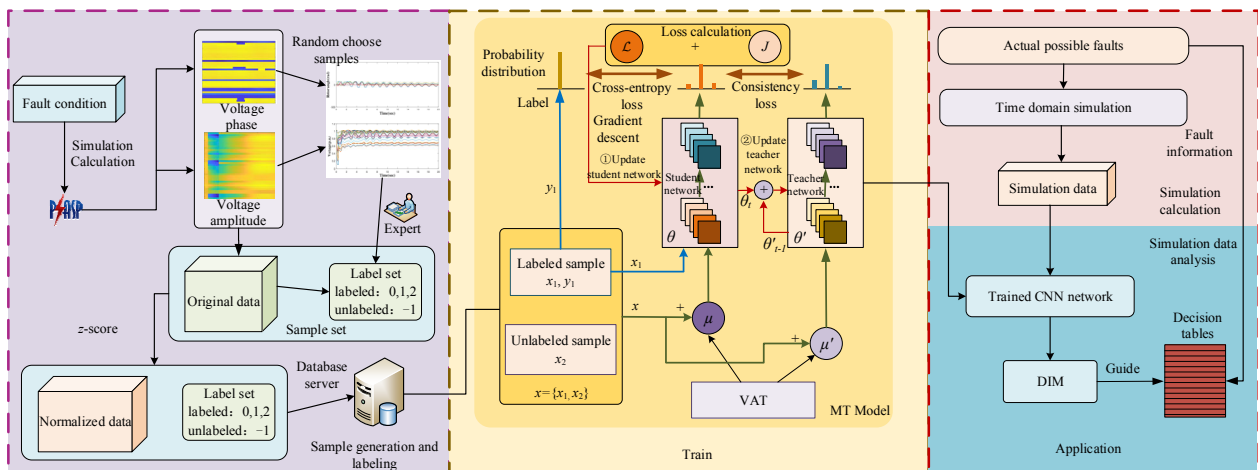


Fig. 1 Overall framework and application flow chart of the mode