

引用格式: 崔亚奇, 熊伟, 何友. 不确定航迹自适应预测模型[J]. 航空学报, 2019, 40(5): 322557. CUI Y Q, XIONG W, HE Y. Adaptive forecast model for uncertain track[J]. Acta Aeronautica et Astronautica Sinica, 2019, 40(5): 322557 (in Chinese). doi: 10.7527/S1000-6893.2018.22557

不确定航迹自适应预测模型

崔亚奇^{*}, 熊伟, 何友

海军航空大学 信息融合研究所, 烟台 264001

摘要: 针对现有航迹预测技术中, 存在无模技术缺乏理论分析支持、能力有限、适用范围窄、有模技术先验假设过多、前提条件严苛、通用性差等问题, 通过理论推导, 利用循环和多层神经网络结构, 研究提出了具有理论严谨、先验假设少、适用范围广、通用性强等优点的不确定航迹自适应预测模型, 同时给出了典型的实现方法。该模型克服了现有航迹预测方法的缺点与不足, 并具有无模与有模两类技术的优点与长处, 仿真和实测实验验证表明: 该模型能很好地提取识别出数据中存在的模式, 并基于模式, 进行正确有效地预测, 能有效解决不同实际环境中的航迹预测问题, 效果明显。

关键词: 航迹预测; 多模预测; 人工智能; 循环神经网络; 多层神经网络

中图分类号: V219; TP953; TN957

文献标识码: A

文章编号: 1000-6893(2019)05-322557-10

航迹预测主要是基于目标历史运动航迹, 对目标未来可能的位置进行预测, 是当前进行正确判断和科学决策的主要依据。作为一项极为关键的基础支撑技术, 航迹预测在民用和军事领域具有广阔的应用场景^[1-3]。例如, 在民用领域, 对船舶的航迹趋势做出正确的判断, 就可以采取相应的措施, 趋利避害, 使目标船舶和附近其他船舶处于安全的运行环境中, 对民航飞机航迹进行精确的预测, 就可以提高空中交通管制的效率, 提供及时、最优的冲突解决方案, 提高空域容量。在军事领域, 目标航迹预测更是贯穿目标识别、目标跟踪、目标打击等作战全环节当中, 譬如可用于异常航迹检测, 识别不明目标; 可用于雷达目标跟踪, 提高目标跟踪连续性; 可以用于导弹对移动目标火力打击, 提高导弹命中概率等。

鉴于目标航迹预测技术重要作用和广泛需求, 当前对目标航迹预测技术进行了多方面、多角度的研究尝试, 取得了大量研究成果。根据是否

需要对目标运动模型进行建模, 现有航迹预测技术可分为无模和有模两大类。其中, 无模技术把航迹预测问题单纯地视为时间序列预测问题, 忽略问题领域知识, 直接选取匹配的方法进行预测, 譬如基于灰色模型的航迹预测方法^[4], 基于 BP 神经网络的航迹预测方法^[5-6]等。此类方法具有前提假设少、模型简单、所需样本数据少的优点, 但对所采用时序方法的合理性, 与实际问题的契合性, 缺乏必要理论论证。同时由于所采用时序模型较为简单、能力有限, 现有无模类方法还存在适用范围窄、泛化能力弱、预测精度低的问题。

有模技术则基于假定的目标运动模型, 采用统计估计理论, 对航迹进行预测。根据假定的目标运动模型数量, 有模技术还可进一步划分为单模^[7-9]和多模两大类^[10-13]。单模技术基于目标仅做一种模式运动的假设进行航迹预测, 常见的目标运动模型有匀速、常加速、协同转弯、Singer、当前统计和 Jerk 等模型, 相匹配的统计估计方法有

收稿日期: 2018-07-19; 退修日期: 2018-08-17; 录用日期: 2018-08-27; 网络出版时间: 2018-10-07 23:15

网络出版地址: <http://hkxb.buaa.edu.cn/CN/html/20190522.html>

基金项目: 国家自然科学基金(61790550, 61790554)

^{*} 通信作者: E-mail: cui_yaqi@126.com

卡尔曼滤波^[7]、扩展卡尔曼滤波^[8]、粒子滤波^[9]等。多模技术^[10-13]则假定目标依据一定概率,按照模型集里面的有限运动模式进行交替运动,其假定的模型集一般比较小,主要包括匀速、常加速、协同转弯等3种模型,相匹配的统计估计方法有交互多模型和高斯和等。有模技术具有理论严谨,性能有保证,实现简单的优点,但由于实际目标运动模型未知多样,此类方法存在先验假设过多,前提条件严苛的问题,进而导致其适用范围有限、通用性差,实际运用效果时好时坏。虽然多模方法一定程度上弱化了目标模型假设,但与实际情况仍存在较大差距,尚没有完全有效解决问题。

综上所述,现有航迹预测技术存在的问题可归纳如下:

1) 无模技术假设简单、通用性强,但其合理性目前缺乏理论分析支持,同时现有方法采用的时序模型较为简单、能力有限,存在适用范围窄、泛化能力弱、预测精度低的问题。

2) 有模技术理论严谨、性能有保证、实现简单,但存在先验假设过多、前提条件严苛的问题,实际运用效果时好时坏、通用性差。

针对上述问题,研究提出不确定航迹自适应预测模型。该模型具有无模与有模两类技术的优点与长处,具备理论严谨、先验假设少、适用范围广、通用性强的优点,无需对目标可能的运动模型进行提前明确,适用于目标运动具有规律性、但具体运动模式不确定的航迹预测问题,可完全有效解决航迹预测问题。

本文首先通过理论推导,构建不确定航迹自适应预测基本理论框架,然后基于神经网络,建立不确定航迹自适应预测(Uncertain Track Adaptive Forecast, UTAF)模型,并生成典型的实现方法,最后通过仿真与实测数据,对其有效性进行验证。

1 模型研究

首先对需要解决的问题进行描述建模,然后根据实际情况,进行合理必要假设。基于此,利用全概率公式,构建问题的基本解决框架,最后采用神经网络设计出有效的模型。

1.1 问题建模

航迹预测主要是由前多个时刻的位置,预测

下一时刻的位置。从概率的角度看,航迹预测就是要求取 $p(y_{t+1} | \{x_1, x_2, \dots, x_t\})$, 并进行最大化,以得到

$$\hat{y}_{t+1} = \underset{y_{t+1}}{\operatorname{argmax}} p(y_{t+1} | \{x_1, x_2, \dots, x_t\}) \quad (1)$$

式中: y_{t+1} 为需要预测的下一时刻真实位置; $\{x_1, x_2, \dots, x_t\}$ 为已知的前多个时刻位置; $p(y_{t+1} | \{x_1, x_2, \dots, x_t\})$ 为以前多个时刻位置作为条件的下一时刻位置的概率; \hat{y}_{t+1} 为预测结果。为了表示方便,在不引起歧义的情况下,去掉 y_{t+1} 、 \hat{y}_{t+1} 的时间标签。

1.2 基本假设

受目标自身性能、或操纵人员习惯、以及其他外部条件影响限制,目标在运动过程中存在一定的规律,并不是毫无章法、随机运动的,譬如受目标自身性能限制,目标的最大加速度、最小转弯半径、巡航速度基本上是确定的,受操纵人员习惯和其他外部条件影响,目标何时加速、何时减速、何时转弯、加速方式、减速方式等,也有特定规律。因此,目标运动是有模式的,但什么类型的目标,具有什么样的运动模式,相应运动模式的多少、规模以及具体内容,以及目标在何时以何种模式运动,对预测者来说,是不确定的,也是难以确定的。

假设目标以一定模式 c 运动,并且目标下一时刻的位置完全由当前的模式 c 确定,即

$$p(y | c, \{x_1, x_2, \dots, x_t\}) = p(y | c) \quad (2)$$

式中: c 为实数向量,包含所有与预测下一时刻相关的信息,由 c 构成的空间 $\{c\}$ 为目标运动模式空间,表示目标所有可能的运动模式。

1.3 基本框架

对于条件概率 $p(y | \{x_1, x_2, \dots, x_t\})$, 由全概率公式,可得

$$p(y | \{x_1, x_2, \dots, x_t\}) = \sum_{\{c\}} p(y | c, \{x_1, x_2, \dots, x_t\}) \cdot p(c | \{x_1, x_2, \dots, x_t\}) \quad (3)$$

基于假设,根据式(2),可进一步得到

$$p(y | \{x_1, x_2, \dots, x_t\}) = \sum_{\{c\}} p(y | c) p(c | \{x_1, x_2, \dots, x_t\}) \quad (4)$$

下面,依据式(4),进一步求取 \hat{y} 。关于求解

\hat{y} , 有两种方式: 一种是软求取(\hat{y}^s); 一种是硬求取。其中软求取是通过求取所有可能预测位置的概率加权和来获得目标预测位置, 如式(5)所示。此种方法与交互多模型类似, 是概率意义上的正确解, 但由于对每个不同的模式 c , 都需要求取相应的最优预测位置 \hat{y}_c , 在实际目标运动模式多样、不确定的情况下, 实施难度较大。

$$\begin{aligned}\hat{y}^s &= \operatorname{argmax}_y p(y | \{x_1, x_2, \dots, x_t\}) = \\ &= \operatorname{argmax}_y \sum_{\{c\}} p(y | c) p(c | \{x_1, x_2, \dots, x_t\}) = \\ &= \sum_{\{c\}} \{ \operatorname{argmax}_y p(y | c) \} p(c | \{x_1, x_2, \dots, x_t\}) = \\ &= \sum_{\{c\}} y_c p(c | \{x_1, x_2, \dots, x_t\})\end{aligned}\quad (5)$$

\hat{y} 的硬求取则选取模式概率最大 c_m 条件下最可能预测位置作为输出, 如式(6)所示。由于目标当前时刻只能以一种模式运动, 因此硬求取是最贴近实际情况, 同时也是最合理的求取方式。后面将以式(6)为基础, 进行 UTAF 模型设计。

$$\begin{aligned}y &= \operatorname{argmax}_y p(y | c_m = \\ &= \operatorname{argmax}_c p(c | \{x_1, x_2, \dots, x_t\}))\end{aligned}\quad (6)$$

由式(6)可知, \hat{y} 的硬求解实际包括两个过程, 分别为模式信息提取过程 I-step, 如式(7)所示, 和预测位置生成过程 E-step, 如式(8)所示。

$$\begin{aligned}c_m &= \operatorname{argmax}_c p(c | \{x_1, x_2, \dots, x_t\}) = \\ &= I(\{x_1, x_2, \dots, x_t\})\end{aligned}\quad (7)$$

$$y = \operatorname{argmax}_y p(y | c_m) = e(c_m)\quad (8)$$

式中: I-step 主要是根据前多个时刻的位置提取目标可能的模式信息, 而 E-step 则根据模式(8)信息, 对目标可能的预测位置进行估计生成。

1.4 模型设计

如果能根据 I-step 和 E-step 过程的信息处理特点, 直接设计出既具有相应功能特征, 又不涉及目标具体运动模式, 同时还能方便求解的一般表示, 则可构建 UTAF 模型, 如图 1 所示。

鉴于神经网络强大的信息提取、模式识别和函数逼近能力, 考虑采用神经网络结构对 I-step 和 E-step 进行一般表示:

1) 循环神经网络 (Recurrent Neural Network, RNN) 是专门处理变长序列数据的网络结构^[14-16], 具有强大的信息记忆、信息提取、信息表




图 1 不确定航迹预测思维图

Fig. 1 Thinking map of uncertain track forecast

示以及模式识别能力, 因此可采用 RNN 对 I-step 进行一般表示:

$$h_i = f(x_i, h_{i-1})\quad (9)$$

$$c = q(\{h_1, h_2, \dots, h_t\})\quad (10)$$

2) 多层神经网络 (Multi-Layer Perceptron, MLP) 具有很强的函数逼近能力, 两层 MLP 即可逼近任意一个连续函数^[17-21], 因此可采用 MLP 对 E-step 进行一般表示:

$$\hat{y} = g(c)\quad (11)$$

因此, 用 RNN 表示 I-step, 用 MLP 表示 E-step, 串联起来, 即为 UTAF 模型, 如图 2 所示。

与现有航迹预测模型方法相比, UTAF 模型具有如下显著特点:

1) 几乎不存在任何先验假设, 唯一要求是目




图 2 UTAF 模型

Fig. 2 UTAF model

标运动有模式,即目标运动事件本身是可预测的,这与实际情况是相符的。

2) 推导严谨,有理论支撑。

3) 采用神经网络结构,模型表达能力强,涵盖维度高,泛化能力强。

4) 能利用大量历史观测数据进行模型训练,符合当前大数据、人工智能技术发展潮流。

2 典型方法

基于已建立的通用模型,采用具体 RNN 和 MLP 结构,通过参数寻优,构建生成典型不确定航迹自适应预测方法(Basic Uncertain Track Adaptive Forecast Method, Basic-UTAFM)。

首先,采用典型 RNN 结构,实现 I-step。典型 RNN 结构包括 Simple-RNN, LSTM (Long Short-Term Memory) 以及 GRU (Gated Recurrent Unit) 等不同网络结构。其中 Simple-RNN 存在长时间信息衰减问题, LSTM 与 GRU 则通过门结构建立了长时间信息保持通道,可有效保留提取长时间信息,并且相对于 LSTM, GRU 结构更加简单有效。因此这里采用 GRU, 详细构建如下:

$$h_i = f(x_i, h_{i-1}) = (1 - z_i) \circ h_{i-1} + z_i \circ \tilde{h}_i \quad (12)$$

$$\tilde{h}_i = \tanh(Wx_i + U(r_i \circ h_{i-1})) \quad (13)$$

$$r_i = \sigma(W_r x_i + U_r h_{i-1}) \quad (14)$$

$$z_i = \sigma(W_z x_i + U_z h_{i-1}) \quad (15)$$

式中: 运算 \circ 表示对应元素相乘; σ 为 Sigmoid 函数; $h_i, r_i, z_i \in \mathbf{R}^n$, h_i 为 RNN 第 i 时刻隐藏层向量, r_i, z_i 为相应时刻的重置门和更新门; n 为隐藏层单元数量, 代表 GRU 的表示能力; $W, W_r, W_z \in \mathbf{R}^{n \times o}$, $U, U_r, U_z \in \mathbf{R}^{n \times n}$ 为权重矩阵; o 表示输入层 x_i 的维度。

需要说明的是, 为了简化表达, 在式(13)~式(15)中, 省略了偏置项。在 MLP 层, 按照相同的原则进行处理, 不再另行交代。

由于 h_i 基本包含了历史观测 $\{x_1, x_2, \dots, x_i\}$ 模式信息, 可以把其直接作为模式, 即

$$c = q(\{h_1, h_2, \dots, h_i\}) = h_i \quad (16)$$

然后, 采用典型 MLP 结构, 具体实现 E-step。由于 GRU 结构已经包括一定量非线性单元, MLP 可以采用简单的一层结构进行目标位置预测, 即

$$\hat{y} = g(c) = W_y h_i \quad (17)$$

式中: $W_y \in \mathbf{R}^{o \times n}$ 为权重矩阵。

最后利用训练数据集, 通过参数训练优化, 生成典型的不确定航迹自适应预测方法。由于航迹预测是回归问题, 可采用均方差作为损失函数, 如式(18), 而后利用梯度下降法进行 $W, U, W_r, U_r, W_z, U_z, W_y$ 权重矩阵参数和偏置项参数寻优。另外训练数据集主要通过历史观测数据来构建, 在构建时, 应注意数据的广泛性和规范性。

$$L(y, \hat{y}) = \sum_j (y_j - \hat{y}_j)^T (y_j - \hat{y}_j) \quad (18)$$

式中: y_j, \hat{y}_j 表示训练数据和预测数据。

采用简单的一层 RNN 和两层 MLP 结构, 示范性生成了 Basic-UTAFM。在实际运用中, 应根据问题的复杂程度, 参照神经网络模型设计、调节、优化的步骤和方法, 依据数据验证结果, 对 RNN 基本结构, RNN 和 MLP 层数, 每层神经元个数, 激励函数类别、正则化、Dropout 等影响神经网络性能的主要配置与选项进行选择和优化。

3 实验验证

为充分验证 UTAF 模型的有效性, 分别进行仿真实验和实测实验, 并与 Baseline 方法进行性能分析比较, 其中仿真实验主要验证 UTAF 模型是否具备多模航迹预测能力, 实测实验主要是在实际问题中对模型的性能表现进行验证分析。Baseline 方法采用时间序列预测中的 Persistence Algorithm, 用 t 时刻数据预测 $t+1$ 时刻数据。

整个实验主要采用 Python 语言, 基于 Keras 和 Tensorflow 深度学习库, 进行 UTAF 建模、训练、优化, 以及与 Baseline 的性能比较分析。

3.1 仿真验证

用余弦、斜三角、阶跃、抛物线等常见基本函数, 表示目标不同的运动模式, 并以其为基础, 混合构建 4 种不同数据集, 分别为不同频率余弦数据集(Different Frequent Cosine data set, DFC)及添加噪声版(Different Frequent Cosine with Noise data set, DFCN), 不同类型函数数据集(Different Kinds Function data set, DKF)及添加噪声版(Different Kinds Function with Noise data set, DKFN)。每种测试数据集包含 4 000 条训练

数据,每种模式 1 000 条,打乱混合在一起,具体构建方法见表 1。其中仿真数据集每条数据的具体构成方法为:按照 200 Hz 的采样频率对不同模式函数进行采样,每种模式的连续 7 个点作为一条训练数据,前 6 个点为输入,第 7 个点为输出。

对于 4 种不同数据集,分别进行 Basic-UTAFM 的训练、验证和测试。由数据集的构成可知,Basic-UTAFM 输入和输出维度 $o = 1$,设置 RNN 隐藏层神经元数量为 $n = 10$ 。数据集按照 9:1 比例划分为训练集、验证集,采用 Adam (Adaptive moment estimation) 寻优方法,按每批 10 条数据进行 Basic-UTAFM 参数更新,共训练遍历 20 次数据集。

首先,以情况较为复杂的 DKFN 数据集为例,通过直观展示预测结果,进行 Basic-UTAFM 预测性能定性分析,如图 3 所示。基于 DKFN 数据集,训练生成的 Basic-UTAFM,能对数据集里面的阶跃函数和抛物线函数进行较为准确的预测,对其他两个函数的预测结果类似。同一个 Basic-UTAFM,相同的参数配准,清晰地表明了 UTAF 和 Basic-UTAFM 能提取识别数据的模式信息,并基于模式进行预测。

进一步对 Basic-UTAFM 预测性能进行定量分析。Basic-UTAFM 在不同数据集的训练误差曲线如图 4 所示,Basic-UTAFM 预测均方误差 (MSE) 如表 2 所示。在表 2 中,性能提升数据列是表示相对于 Baseline,Basic-UTAFM 预测精度提升的百分比,其计算公式为 $(1 - \text{MSE}_{\text{Basic-UTAFM}} / \text{MSE}_{\text{Baseline}}) \times 100$,单位为 %。

表 1 仿真数据集
Table 1 Simulation datasets

名称	包含模式
DFC	模式 1 设置为余弦函数,周期 1 Hz
	模式 2 设置为余弦函数,周期 5 Hz
	模式 3 设置为余弦函数,周期 10 Hz
	模式 4 设置为余弦函数,周期 20 Hz
DKF	模式 1 设置为余弦函数,周期 10 Hz
	模式 2 设置为阶跃函数,周期 10 Hz
	模式 3 为斜三角函数,周期 10 Hz
	模式 4 为抛物线函数,周期 10 Hz
DFCN	与 DFC 构成相同,但添加均值为 0,方差为 0.04 的高斯白噪声
DKFN	与 DKF 构成相同,但添加均值为 0,方差为 0.01 的高斯白噪声




图 3 Basic-UTAFM 与 Baseline 预测结果对比
Fig. 3 Comparison of forecast results between Basic-UTAFM and Baseline method

由图 4 和表 2 可知,Basic-UTAFM 在 4 种数据集下均能得到收敛的结果,并且与 Baseline 方法相比,预测性能提升明显:① 在 DFC 数据集上,误差曲线下降趋势明显,训练曲线与验证曲线基本重合,与 Baseline 相比,性能提升 99.86%,表明在数据变化连续、模式清晰可辨的情况下,Basic-UTAFM 具有很好的预测效果;② 在 DF-CN 数据集上的表现,与 DFC 数据集上基本相同,但由于噪声的影响,模式的可辨性变差,性能存在一定程度下降,变为 69.24%,并且在模式 1 数据上性能提升为 -15.11%,分析主要是由于“模式 1”周期为 1 Hz,在相同 200 Hz 数据采用频率下,相邻时刻采样点间数值差别较小,如果进一步受噪声影响,则相邻时刻数值表现为来回摆动,变化趋势微弱、不明显,模式不易被 Basic-UTAFM 识别,导致模式 1 预测存在一定困难,Basic-UTAFM 预测性能有一定程度下降问题。但是可以肯定,在噪声情况下,如果数据模式仍旧可




图 4 不同数据集下 Basic-UTAFM 训练误差曲线
Fig. 4 Curves of basic-UTAFM training error
using different datasets

辨,则 Basic-UTAFM 仍能取得较好的预测效果;
③ 在 DKF 和 DKFN 数据集上,误差曲线下降趋势同样比较明显,与 Baseline 相比,性能分别提升 36.37%和 33.61%。但验证曲线围绕训练曲线存在一定上下波动,表明此类数据集下,Basic-UTAFM 在部分数据上有较差表现。结合表 2 可知,Basic-UTAFM 主要是对模式 2 阶跃函数的预测效果差,相对于 Baseline,性能仅提升 16.57%和 17.61%,不及整体平均水平。分析主要是由于阶跃函数存在突变,模式辨别存在困难所导致的,而噪声情况下性能 1%的提升,也主要是由于噪声一定程度上缓解了阶跃函数突变效果的原因。

进一步,DFC 数据集下 100 次蒙特卡罗仿真结果如图 5 所示。可知,除了在模式 1 数据上,存在少量与 Baseline 性能相当的异常点外,Basic-UTAFM 在大部分仿真中对模式 1 预测性能,所有仿真对其他模式预测性能,和在所有仿真中的整体预测性能,均明显优于 Baseline,有力地说明

表 2 Basic-UTAFM 预测性能比较 (仿真数据)				
Table 2 Comparison of Basic-UTAFM with baseline forecast performances (simulation data)				
名称	数据	Basic-UTAFM	Baseline	性能提升/%
DFC	模式 1	8.80×10^{-5}	4.93×10^{-4}	99.86
	模式 2	4.20×10^{-5}	1.23×10^{-2}	99.65
	模式 3	1.25×10^{-4}	5.02×10^{-2}	99.75
	模式 4	8.90×10^{-5}	1.95×10^{-1}	99.95
	全部	8.60×10^{-5}	6.45×10^{-2}	99.86
DKF	模式 1	2.92×10^{-3}	5.02×10^{-2}	94.19
	模式 2	2.94×10^{-1}	3.52×10^{-1}	16.57
	模式 3	7.99×10^{-3}	4.00×10^{-2}	80.02
	模式 4	4.81×10^{-3}	4.40×10^{-2}	89.06
	全部	7.73×10^{-2}	1.22×10^{-1}	36.37
DFCN	模式 1	2.35×10^{-2}	2.04×10^{-2}	-15.11
	模式 2	2.28×10^{-2}	3.17×10^{-2}	27.99
	模式 3	3.36×10^{-2}	7.29×10^{-2}	53.95
	模式 4	2.75×10^{-2}	2.16×10^{-1}	87.28
	全部	2.61×10^{-2}	8.49×10^{-2}	69.24
DKFN	模式 1	1.96×10^{-2}	7.13×10^{-2}	72.54
	模式 2	3.13×10^{-1}	3.80×10^{-1}	17.61
	模式 3	6.15×10^{-2}	2.76×10^{-2}	55.16
	模式 4	6.59×10^{-2}	2.52×10^{-2}	61.77
	全部	9.34×10^{-2}	1.41×10^{-1}	33.61

了 Basic-UTAFM 的有效性和稳定性。

下面对 Basic-UTAFM 训练耗时和预测耗时进行分析,如表 3 所示,共设置 4 种不同大小数据集,采用与上面相同的模型设置和训练设置,每个数据集上训练模型 20 次,训练所用计算机 CPU 为至强 E5-1620 v4 3.5 GHz,内存为 16 G,没有利用 GPU 加速运算。

由表 3 可知,当数据集大小为 4 000 时,总训练耗时、单次训练耗时和每 1 000 次的预测耗时分别为 74.24、3.71、0.110 s,训练耗时大,预测耗时很小,并且随着数据集增大,训练耗时线性增加,而预测耗时有一定程度下降,稳定在 0.063 s,符合神经网络训练特点。按照神经网络实际运用方法,由于模型训练耗时比较大,预测耗时比较小,可以在线下对模型进行训练,训练成功后,在线上部署预测。

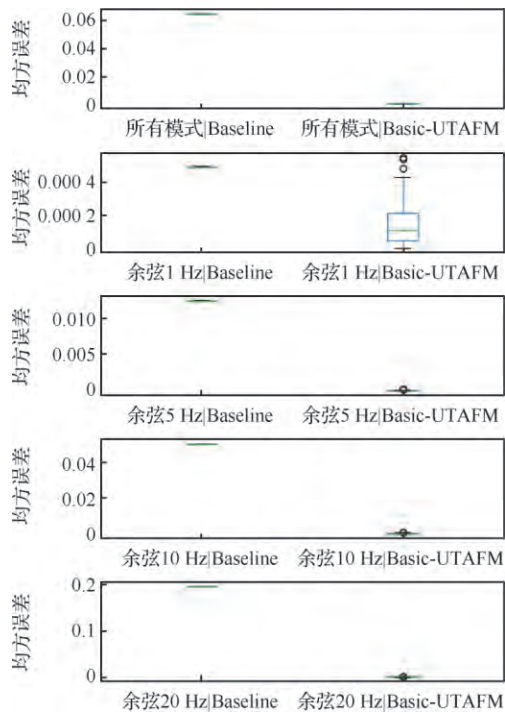


图 5 DFC 数据集下 100 次蒙特卡罗仿真 Basic-UTAFM 预测 MSE 箱形图
Fig. 5 Basic-UTAFM MSE boxplot through 100 Monte Carlo using DFC dataset

表 3 Basic-UTAFM 耗时分析

Table 3 Basic-UTAFM time-consuming analysis

数据集大小	总训练耗时/s	单次训练耗时/s	每 1000 次的预测耗时/s
4 000	74.24	3.71	0.110
8 000	157.16	7.86	0.070
40 000	732.10	36.61	0.063
80 000	1 475.44	73.77	0.063

综合上述分析,可以肯定:在数据集包含多种模式,并且不同模式间清晰可辨情况下,UTAF模型和具体 Basic-UTAFM 能很好地提取识别出数据模式,并基于模式,进行正确有效地预测。

3.2 实测验证

进一步,通过民航飞机空中位置预测,对 UTAF 模型和具体 Basic-UTAFM 进行实测数据验证。由于飞机当前航迹点位置是由上时刻位置、加航速与时间差乘积得到的,存在确定趋势,是非平稳的,不能直接作为神经网络输入,而飞机航速的变化是平稳的,因此这里通过对航速的预

测,来实现飞机航迹的预测,同时由于经度方向速度和纬度方向速度基本是不相关的,可以对其进行分别预测。

利用 ADS-B 设备,采集民航飞机航行轨迹数据,见图 6,构建民航飞机航迹数据集(Civil Aviation Flight Track data set, CAFT),具体构建方法见表 4。其中 T_{\max} 表示所有航迹内航迹点间的最大时间间隔。航迹点间时间间隔越小,航速可能的变化也就越小,信息的不确定性相应也比较小,因此需要根据 T_{\max} 把 CAFT 分成存在包含关系的 5 类数据集,即 CAFT-60 包含 CAFT-50、CAFT-50 包含 CAFT-40 等。另外,在实际训练时,还需要设定最大航速,对航速数据进行归一化处理,把航速限定在 $[0, 1]$ 或 $[-1, 1]$ 范围内。其中实测数据集每条数据的具体构成方法为:对每条目标航迹,按照时间先后,求取经度方向和纬度方向航速序列,然后顺序取 6 个连续时刻航速数据作为输入,相邻的后一个航速数据做输出,进而构成一条数据,一条目标航迹可构成多条数据。

表 4 民航飞机航迹数据集

Table 4 Civil aviation flight track data set

名称	T_{\max}/s	(训练集大小、验证集大小)
CAFT-20	20	(860, 90)
CAFT-30	30	(7 630, 840)
CAFT-40	40	(32 170, 3 570)
CAFT-50	50	(62 550, 6 950)
CAFT-60	60	(94 080, 10 450)

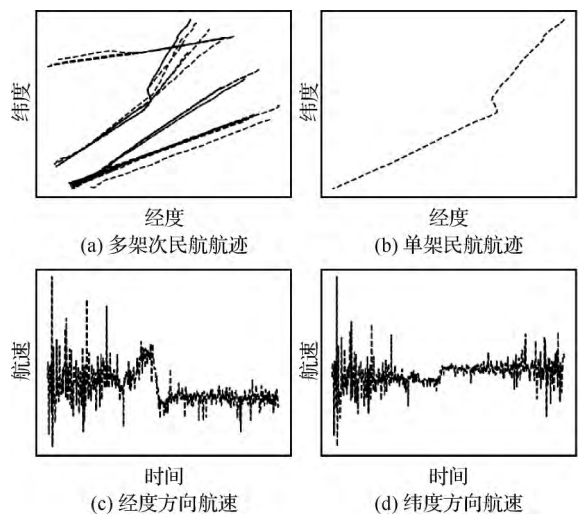


图 6 民航飞机航迹和航速示意图

Fig. 6 Schematic diagram of civil aviation flight track and velocity

对于 5 类 CAFT 数据集,分别进行 Basic-UTAFM 的训练、验证和测试。由数据集的构成可知,Basic-UTAFM 输入和输出维度 $o = 1$,设置 RNN 隐藏层神经单元数量为 $n = 10$ 。采用 Adam 自适应寻优方法,按每批 5 条数据进行 Basic-UTAFM 参数更新,共训练遍历 10 次数据集,Basic-UTAFM 在 CAFT-20 数据集下的训练过程误差曲线如图 7 所示。由图可见,Basic-UTAFM 收敛速度快、稳定性强,训练曲线与验证曲线也基本吻合,表明 Basic-UTAFM 能实现飞机航迹的预测,能解决实际航迹预测问题。

Basic-UTAFM 预测 MSE 如表 5 所示,其中纬度方向和经度方向航速分别采用两个不同的 Basic-UTAFM 进行预测,合成表示两个 Basic-UTAFM 对绝对速度的预测结果,即对纬度方向与经度方向速度的 L2 范数的预测结果。

由表 5 可知,Basic-UTAFM 在 5 类实测数据集,10 个航速预测问题中均能得到良好的结果,并且与 Baseline 方法相比,最低提升 30.91%,最高提升 36.87%,大部分提升 33%左右,预测性能提升明显。

综合上述分析,实测实验结果有力地表明 Basic-UTAFM 具有较强的适应性,能有效地解决不同实际环境中的航迹预测问题,效果明显。




图 7 CAFT-20 数据集下 Basic-UTAFM 训练误差曲线

Fig.7 Curves of Basic-UTAFM training error using CAFT-20 dataset

表 5 Basic-UTAFM 预测性能比较(实测数据)

Table 5 Comparison of Basic-UTAFM with baseline forecast performance (measured data)

名称	类别	Basic-UTAFM/ 10^{-2}	Baseline/ 10^{-2}	性能提升/%
CAFT-20	纬度	1.75	2.78	36.87
	经度	1.46	2.12	30.91
	合成	1.87	3.14	40.44
CAFT-30	纬度	1.49	2.25	33.83
	经度	1.37	2.05	33.11
	合成	1.57	2.56	38.65
CAFT-40	纬度	1.24	1.84	32.58
	经度	1.17	1.76	33.36
	合成	1.24	1.94	36.37
CAFT-50	纬度	1.08	1.61	32.47
	经度	1.19	1.73	31.53
	合成	1.10	1.72	36.13
CAFT-60	纬度	1.03	1.52	32.03
	经度	1.13	1.72	33.99
	合成	1.00	1.62	38.17

4 结 论

1) 不确定航迹自适应预测模型具备理论严谨,先验假设少,适用范围广、通用性强等优点,克服了现有无模和有模两类技术的缺点与不足。

2) 仿真和实测实验验证清晰表明:不确定航迹自适应预测模型和相应的具体实现方法能很好地提取识别出数据模式,并基于模式,进行正确有效地预测,能有效地解决不同实际环境中的航迹预测问题,效果明显。

参 考 文 献

- [1] 郭运韬,朱衍波,黄智刚. 民用飞机航迹预测关键技术研究[J]. 中国民航大学学报, 2007, 25(1): 20-24.
GUO Y T, ZHU Y B, HUANG Z G. Study on key trajectory prediction techniques of civil aviation aircraft[J]. Journal of Civil Aviation University of China, 2007, 25(1): 20-24 (in Chinese).
- [2] WILSON R C, WHITLEY T D, ESTKOWSKI R. Trajectory prediction: USA, US20060224318[P]. 2006.
- [3] ALAHI A, GOEL K, RAMANATHAN V, et al. Social LSTM: Human trajectory prediction in crowded spaces [C]//Computer Vision and Pattern Recognition. Piscat-

- away, NJ: IEEE Press, 2016: 961-971.
- [4] 邸忆, 顾晓辉, 龙飞. 基于灰色残差修正理论的目标航迹预测方法[J]. 兵工学报, 2017, 38(3): 454-459.
- DI Y, GU X H, LONG F. Target track prediction method based on grey residual modification theory[J]. Acta Armamentarii, 2017, 38(3): 454-459 (in Chinese).
- [5] 谭伟, 陆百川, 黄美灵. 神经网络结合遗传算法用于航迹预测[J]. 重庆交通大学学报(自然科学版), 2010, 29(1): 147-150.
- TAN W, LU B C, HUANG M L. Track prediction based on neural networks and genetic algorithm[J]. Journal of Chongqing Jiao Tong University(Natural Science), 2010, 29(1): 147-150 (in Chinese).
- [6] 钱夔, 周颖, 杨柳静, 等. 基于 BP 神经网络的空中目标航迹预测模型[J]. 指挥信息系统与技术, 2017, 8(3): 54-58.
- QIAN K, ZHOU Y, YANG L J, et al. Aircraft target track prediction model based on BP neural network[J]. Command Information System and Technology, 2017, 8(3): 54-58 (in Chinese).
- [7] FANG W, ZHENG L. Rapid and robust initialization for monocular visual inertial navigation within multi-state Kalman filter[J]. Chinese Journal of Aeronautics, 2018, 31(1): 148-160.
- [8] 赵洲, 黄攀峰, 陈路. 一种融合卡尔曼滤波的改进时空上下文跟踪算法[J]. 航空学报, 2017, 38(2): 269-279.
- ZHAO Z, HAUNG P F, CHEN L. A tracking algorithm of improved spatio-temporal context with Kalmans filter[J]. Acta Aeronautica et Astronautica Sinica, 2017, 38(2): 269-279 (in Chinese).
- [9] LU Z Y, BA B, WANG J H, et al. A direct position determination method with combined TDOA and FDOA based on particle filter[J]. Chinese Journal of Aeronautics, 2018, 31(1): 161-168.
- [10] HAN H Z, WANG J, DU M Y. GPS/BDS/INS tightly coupled integration accuracy improvement using an improved adaptive interacting multiple model with classified measurement update[J]. Chinese Journal of Aeronautics, 2018, 31(3): 556-566.
- [11] 翟岱亮, 雷虎民, 李炯, 等. 基于自适应 IMM 的高超声速飞行器航迹预测[J]. 航空学报, 2016, 37(11): 3466-3475.
- ZHAI D L, LEI H M, LI J. Trajectory prediction of hypersonic vehicle based on adaptive IMM[J]. Acta Aeronautica et Astronautica Sinica, 2016, 37(11): 3466-3475 (in Chinese).
- [12] 张翔宇, 王国宏, 李俊杰, 等. 临近空间高超声速滑跃式航迹目标跟踪技术[J]. 航空学报, 2015, 36(6): 1983-1994.
- ZHANG X Y, WANG G H, LI J J, et al. Tracking of hypersonic sliding target in near-space[J]. Acta Aeronautica et Astronautica Sinica, 2015, 36(6): 1983-1994 (in Chinese).
- [13] 吴楠, 陈磊. 高超声速滑翔再入飞行器弹道估计的自适应卡尔曼滤波[J]. 航空学报, 2013, 34(8): 1960-1971.
- WU N, CHEN L. Adaptive Kalman filtering for trajectory estimation of hypersonic glide reentry vehicles[J]. Acta Aeronautica et Astronautica Sinica, 2013, 34(8): 1960-1971 (in Chinese).
- [14] CHO K, VAN MERRIENBOER B, GULCEHRE C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[J]. Computer Science, 2014(6): 1-4.
- [15] MAO J, XU W, YANG Y, et al. Deep captioning with multimodal recurrent neural networks (m-RNN) [J]. Eprint Arxiv, 2014: 1-15.
- [16] CHEN S H, HWANG S H, WANG Y R. An RNN-based prosodic information synthesizer for Mandarin text-to-speech[J]. IEEE Transactions on Speech & Audio Processing, 1998, 6(3): 226-239.
- [17] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436.
- [18] SCHMIDHUBER J R. Deep learning in neural networks [M]. Amsterdam: Elsevier Science Ltd., 2015.
- [19] SCHMIDHUBER J R. Deep learning in neural networks: An overview[J]. Neural Netw, 2015, 61: 85-117.
- [20] TORRES J F, TRONCOSO A, KOPRINSKA I, et al. Deep learning for big data time series forecasting applied to solar power[C] // International Joint Conference SOCO'18-CISIS'18-ICEUTE'18. Berlin: Springer, 2019.
- [21] CHEN S, WEN J, ZHANG R. GRU-RNN based question answering over knowledge base [C] // Knowledge Graph and Semantic Computing: Semantic, Knowledge, and Linked Big Data. Berlin: Springer, 2016: 80-91.

(责任编辑: 李丹)

Adaptive forecast model for uncertain track

CUI Yaqi^{*}, XIONG Wei, HE You

Institute of Information Fusion, Naval Aeronautical University, Yantai 264001, China

Abstract: There are two types track forecast technologies at present. One is model-free type technologies which have little theoretical support, limited capacity and narrow scope of application. The other is model type technologies which have too many prior hypothesis, strict prerequisite conditions and poor universality. Against above problems and to solve the track forecast problem effectively, an uncertain track adaptive forecast model and corresponding exemplary implementation are proposed based on the structures of recurrent neural network and the multi-layer neural network. The proposed model has rigorous theoretical support, less a priori hypotheses, wide application range and strong versatility, which inherits benefits and overcomes weaknesses of existing track forecast methods. Simulation and experimental results show that the proposed model can extract and recognize the patterns in the data set, and make correct and effective prediction according to the recognized pattern, significantly solving the track forecast problems in real environments.

Keywords: track forecast; multi-model forecast; artificial intelligence; recurrent neural network; multi-layer neural network;

Received: 2018-07-19; Revised: 2018-08-17; Accepted: 2018-08-27; Published online: 2018-10-07 23:15

URL: <http://hkxb.buaa.edu.cn/CN/html/20190522.html>

Foundation items: National Natural Science Foundation of China (61790550, 61790554)

^{*} Corresponding author. E-mail: cui_yaqi@126.com