

# 卫星与雷达位置数据自适应关联

熊振宇, 崔亚奇, 熊 伟, 顾祥岐

(海军航空大学信息融合研究所, 山东 烟台 264001)

**摘 要:** 卫星与雷达间的数据关联能够实现海上预警探测过程中由大范围预警向精细跟踪过渡转换, 但传统关联模型关联速度慢且难以适应舰船编队目标的非刚性变换、虚警漏报等情形。对此, 提出一种卫星与雷达位置数据自适应关联模型。首先, 采用多层神经网络提取卫星数据和雷达数据整体差异参数。然后, 将参数通过位移变换估计网络实现两类信源目标的匹配, 解决不同信源间的时间间隔和定位误差导致的空间位置差异。最后, 对匹配后的目标进行关联判决。仿真实验结果表明, 该模型关联速度快, 精度高, 能够实时处理大规模多源数据关联任务。同时在应对非刚性变换、定位误差、虚警漏报等场景下有较好的鲁棒性。

**关键词:** 多源数据关联; 舰船编队目标; 神经网络; 自适应模型; 空间位置误差

**中图分类号:** V 219; TP 79; TN 957 **文献标志码:** A **DOI:** 10.3969/j.issn.1001-506X.2021.01.12

## Adaptive association for satellite and radar position data

XIONG Zhenyu, CUI Yaqi, XIONG Wei, GU Xiangqi

(Research Institute of Information Fusion, Naval Aviation University, Yantai 264001, China)

**Abstract:** The data association between satellite and radar can realize the transition from large-scale early warning to fine tracking in the process of the early warning detection. However, the traditional association model has a slow association speed and is difficult to deal with the non-rigid transformation, false alarm and missing detection of ship formation targets. In this regard, an adaptive association model is presented for satellite and radar position data. Firstly, the multi-layer network (MLN) is used to extract the global difference parameters of the satellite data and the radar data. Then, in order to solve the spatial position error caused by time interval and positioning error, the parameters are put into the network of displacement transformation estimation to match the targets from the two types of sources. Finally, an association judgment is accomplished for the matched targets. Simulation and experimental results show that the proposed model achieves good performance both on speed and accuracy, and can handle the large-scale multi-source data association in real-time application. Besides, the model has good robustness under the conditions of non-rigid transformation, positioning error, false alarm and missing detection.

**Keywords:** multi-source data association; ship formation target; neural network; adaptive model; spatial position error

## 0 引 言

随着监视技术的不断发展, 对目标的探测手段日益增多, 探测能力逐步增强。然而不同探测手段所获取的数据间差异不断增大, 对于当前有限的关联融合能力, 不仅没有提升整体的监视能力, 还导致了更多问题。多源数据关联

主要用于判断对同一目标描述的一致性<sup>[1]</sup>, 是多源数据融合的前提和基础, 在军事和民用领域都有广泛的应用<sup>[2-5]</sup>。例如目标识别、海洋监视、目标跟踪、环境监测等。本文主要研究卫星和雷达位置数据间的关联问题。卫星探测范围广、重访周期长、定位精度差, 一般在监视过程中用于大范围探测<sup>[6]</sup>; 雷达探测范围小, 更新周期短, 定位精度高, 一般

收稿日期: 2020-03-29; 修回日期: 2020-06-03; 网络优先出版日期: 2020-08-11。

网络优先出版地址: <https://kns.cnki.net/kcms/detail/11.2422.TN.20200811.1832.004.html>

基金项目: 国家自然科学基金(61032001)资助课题

引用格式: 熊振宇, 崔亚奇, 熊伟, 等. 卫星与雷达位置数据自适应关联[J]. 系统工程与电子技术, 2021, 43(1): 91-98.

**Reference format:** XIONG Z Y, CUI Y Q, XIONG W, et al. Adaptive association for satellite and radar position data[J]. Systems Engineering and Electronics, 2021, 43(1): 91-98.

在监视过程中用于目标的连续跟踪监视<sup>[7]</sup>。卫星与雷达之间的关联可以将两者的信息有效综合起来,互补两类信息各自的不足,实现目标的完全掌握。为有效综合集成空间信息网络中的多源信息,形成多手段联合的预警探测体系,大差异多源信息关联是最亟待突破的难题<sup>[8-10]</sup>。

为解决多源数据关联问题,文献[11-13]以雷达与无源雷达两种手段间关联为背景,解决雷达信息与定位精度差的无源雷达信息间的关联问题。文献[14]利用传统方法提取出舰船目标的拓扑结构特征和属性特征,同时引入了 Dempster-Shafer(简称为 DS)证据理论<sup>[15]</sup>解决了成像遥感信息和卫星电子信息间的舰船目标关联问题。文献[16]采用相干点集(coherent point set, CPS)分析法建立多模态融合模型,利用成像遥感信息和卫星电子信息中目标的位置坐标和属性特征实现关联匹配。文献[17]将高斯混合模型(Gaussian mixture model, GMM)<sup>[18]</sup>和一致性漂移算法(coherent point drift, CPD)<sup>[19]</sup>相结合,提出了非均匀 GMM(inhomogeneous GMM, IGMM),采用期望最大值(expectation maximum, EM)<sup>[20]</sup>计算关联匹配结果。以上解决多源数据关联问题都采用了迭代优化的传统关联方法,存在的主要缺点有:关联成功率低、泛化能力弱、适用范围有限、关联速度慢、人工干预强等问题。同时上述关联方法仅解决了形式简单、条件理想情况下的关联问题,而对于雷达和卫星图像此类更一般、更实际、更具代表性的关联问题缺乏研究。

针对上述问题,本文提出了一种卫星与雷达位置数据自适应关联模型。首先基于多层神经网络(multi-layer neural network, MLN)搭建整体差异参数提取网络,分别提取卫星目标点和雷达目标点的整体差异参数。接着采用串联等方式整合提取到的差异参数得到全局差异参数。然后将全局参数通过设计的位移变换网络实现两类信源目标的配准对齐。最后根据定义的关联判别准则对配准后的目标点进行关联判断。仿真实验结果表明,该模型能够很好地适应队形变换、定位出差、虚警漏报等场景,有效提高了关联速度和精度。

## 1 问题描述

假设同一时刻卫星在某一区域内探测到目标点位置集合为  $S$ , 雷达探测到目标点位置集合为  $G$ 。由于雷达探测较为连续,可以雷达为参考,卫星向雷达进行关联。实测数据分析发现,卫星量测与雷达量测间受时间间隔和定位误差的影响产生较大的空间差异。其中受时间间隔影响,目标点位置的整体差异具有一致性,同时每个点受定位误差的影响,目标点之间的差异还具有个体波动性。因此,雷达与卫星量测点关联问题可描述为

$$(\hat{m}, \hat{o}) = \underset{m, o, \lambda}{\operatorname{argmin}} \sum_{i=1}^N D(x^r(m(i)) - (x^s(i) + o(x^s(i), \lambda))) \quad (1)$$

式中,  $x^s(i)$  表示卫星探测的目标点  $i$  的位置,  $x^s(i) \in S$ ;  $\lambda$  表示整体差异参数,用于描述两种信源的目标点由于时间间隔导致的位置结构上的整体差异;  $o(\cdot)$  表示空间差异函数,用于估计从卫星目标点到雷达目标点的位移变换;  $m$  表示映射函数,用于描述每个卫星目标和雷达目标间的对应关联关系;  $x^r(m(i))$  则表示雷达目标点  $m(i)$  的位置,即与卫星探测的目标点  $i$  相关联的雷达目标点  $m(i)$  位置,  $x^r(m(i)) \in G$ ;  $D(\cdot)$  表示距离度量,用于计算每个雷达目标点和卫星目标点间的距离,距离越小关联程度越高;  $N$  表示目标点数量;  $\hat{m}$  和  $\hat{o}$  分别表示最优映射函数和最优空间差异函数。

## 2 模型设计

卫星与雷达探测的目标点空间差异性大,难以直接进行关联匹配,需对两种信源中每个目标点先配准对齐,再关联判断,同时空间差异函数  $o(\cdot)$  的优化不受映射函数  $m$  的影响,而映射函数  $m$  取决于空间差异函数  $o(\cdot)$  的优化程度。所以采取先优化空间差异函数  $o(x^s(i), \lambda)$ , 后优化映射函数  $m(i)$  的思路设计模型。

(1) 对于优化  $o(x^s(i), \lambda)$ , 采取先整体后个体的方式进行模型设计,网络模型如图 1 所示。

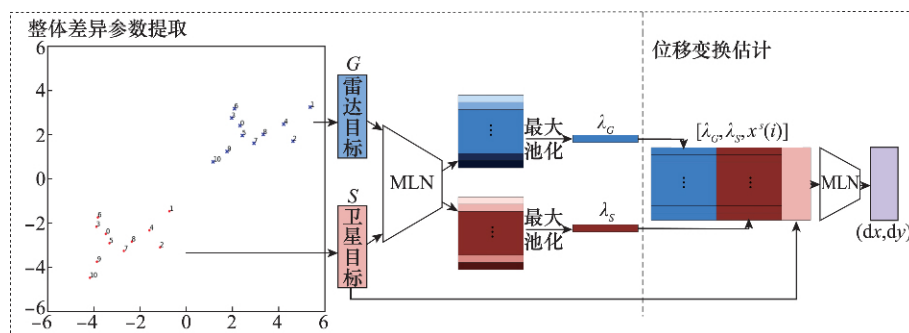


图 1 网络模型

Fig. 1 Network model

卫星目标点  $x^s(i)$  通过位移变换  $\Gamma$  能够逼近对应关联的雷达目标点  $x^r(m(i))$ 。卫星目标点  $x^s(i)$  的变换过程为

$$\Gamma(x^s(i), o) = x^s(i) + o(x^s(i), \lambda) \quad (2)$$

首先利用神经网络强大的信息提取能力,采用 MLN 和最大池化函数提取卫星和雷达目标点的整体差异参数  $\lambda$ 。再利用神经网络强大的函数逼近能力,将整体差异参数  $\lambda$

与卫星目标点集  $S$  串联整合后通过多层神经网络估计卫星目标点到雷达目标点的位移变换  $o(x^s(i), \lambda)$ 。

(2) 对于优化映射函数  $m(i)$ , 通过先计算关联矩阵再采用最大关联系数法配对实现每个雷达目标点和位移后的卫星目标点间的关联。

### 2.1 整体差异参数提取

时间间隔导致卫星与雷达目标点的空间差异具有一致性, 设计整体差异参数提取网络提取出目标点显著性的差异特征。整体差异参数提取网络如图 2 所示。




图 2 整体差异参数提取网络

Fig. 2 Network of global difference parameter extraction

首先, 将卫星和雷达目标点集合  $D = \{(S, G) | S, G \subset \mathbb{R}^2\}$  作为网络的输入部分, 该网络采用了含有 ReLU 激活函数的多层神经网络:  $\{f_i\}_{i=1,2,\dots,t}$ , 其中  $t$  为网络的层数, 然后将网络的输出通过最大池化函数进行归一化处理, 提取到整体差异参数  $\lambda = \{(\lambda_S, \lambda_G) | \lambda_S, \lambda_G \subset \mathbb{R}^d\}$ , 其中  $d$  为参数的维度, 最后将提取到的差异参数串联  $[\lambda_S, \lambda_G]$ 。整体差异参数提取网络结构如表 1 所示。该网络的表达式为

$$\lambda_S = \text{Maxpool}\{f_t f_{t-1} \dots f_1(x^s(i))\}_{x^s(i) \in S} \quad (3)$$

$$\lambda_G = \text{Maxpool}\{f_t f_{t-1} \dots f_1(x^r(j))\}_{x^r(j) \in G} \quad (4)$$

表 1 整体差异参数提取网络结构

Table 1 Network structure of global difference parameter extraction

网络层	输入尺寸	网络参数	输出尺寸
MLN-1	$M \times N \times 2$	$1 \times 1 \times 16$	$M \times N \times 16$
MLN-2	$M \times N \times 16$	$1 \times 1 \times 64$	$M \times N \times 64$
MLN-3	$M \times N \times 64$	$1 \times 1 \times 128$	$M \times N \times 128$
MLN-4	$M \times N \times 128$	$1 \times 1 \times 256$	$M \times N \times 256$
MLN-5	$M \times N \times 256$	$1 \times 1 \times 512$	$M \times N \times 512$
Maxpool	$M \times N \times 512$	$1 \times N \times 1$	$M \times 1 \times 512$

该网络采用了 5 层 MLN 结构, 即  $t=5$ , 网络输出的维度为 512 维, 即  $d=512$ 。其中,  $M$  为训练过程中每一批次数据的大小。

### 2.2 位移变换估计

在位移变换的过程中, 通过第 2.1 节所提网络不仅能够保证卫星数据中的目标和雷达数据中的目标尽可能重合, 同时还能保证位移变换函数连续且平滑。位移变换估计网络如图 3 所示。




图 3 位移变换估计网络

Fig. 3 Network of displacement transformation estimation

首先将串联后的整体差异参数  $[\lambda_S, \lambda_G]$  复制  $N$  次, 目的是让复制后的维度与卫星数据的维度相同; 然后将卫星数据与复制后的差异参数串联得到全局差异参数  $[\lambda_S, \lambda_G, x^s(i)]$ ; 最后将全局差异参数作为输入通过带有 ReLU 激活函数的多层神经网络:  $\{g_i\}_{i=1,2,\dots,s}$  中, 所以空间差异函数为  $o = g_s g_{s-1} \dots g_1$ 。位移变换估计网络的表达式为

$$dx^s(i) = g_s g_{s-1} \dots g_1([\lambda_S, \lambda_G, x^s(i)]) \quad (5)$$

$$\hat{S} = \Gamma(S) = \{x^s(i) + dx^s(i)\}_{x^s(i) \in S} \quad (6)$$

式中,  $\hat{S}$  表示卫星目标点经过位移变换后的位置点集合;  $dx^s(i)$  表示对卫星数据中第  $i$  个目标点移动轨迹的估计。位移变换估计网络结构如表 2 所示。

表 2 位移变换估计网络结构

Table 2 Network structure of displacement transformation estimation

网络层	输入尺寸	网络参数	输出尺寸
MLN-6	$M \times N \times 512$	$1 \times 1 \times 256$	$M \times N \times 256$
MLN-7	$M \times N \times 256$	$1 \times 1 \times 128$	$M \times N \times 128$
MLN-8	$M \times N \times 128$	$1 \times 1 \times 2$	$M \times N \times 2$

考虑到卫星数据与雷达数据中每个目标点都存在对应关系, 采用倒角距离<sup>[21]</sup>进行度量。为了让卫星数据的目标点经位移变换后与雷达数据的目标点距离接近, 该模型的损失函数倒角损失定义如下:

$$L(\hat{S}, G | \theta) = \sum_{x^s(i) \in \hat{S}} \max \left( \min_{x^r(j) \in G} \|\hat{x}^s(i) - x^r(j)\|_2^2, \beta \right) + \sum_{x^r(j) \in G} \max \left( \min_{x^s(i) \in \hat{S}} \|\hat{x}^s(i) - x^r(j)\|_2^2, \beta \right) \quad (7)$$

式中,  $\theta$  为该关联网络模型中需要训练的参数;  $\beta$  为超参数, 在实验中  $\beta=0.1$ 。

### 2.3 关联判决

计算位移变换后卫星目标点位置  $\hat{x}^s(i)$  与雷达目标点位置  $x^r(j)$  的距离, 求得关联系数矩阵  $C(i, j)$  ( $i=1, 2, \dots, N; j=1, 2, \dots, M$ ), 不存在虚警漏报时  $M=N$ 。

$$C(i, j) = \|\hat{x}^s(i) - x^r(j)\|_2^2 = \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1j} \\ c_{21} & c_{22} & \dots & c_{2j} \\ \vdots & \vdots & \ddots & \vdots \\ c_{i1} & c_{i2} & \dots & c_{ij} \end{bmatrix}^2 \quad (8)$$

系数矩阵中若  $c_{ij}$  在该行和该列中都能取得最大值, 则对应的目标点  $\hat{x}^s(i)$  和  $x^r(j)$  关联。经位移变换后的卫星数据目标点  $\hat{x}^s(i)$  与雷达数据目标点  $x^r(j)$  为同一目标, 即  $m(i)=j$ 。

基于以上原则采用最大关联系数法进行关联判断, 具体过程如下:

(1) 首先, 在关联系数矩阵  $C(i, j)$  中找出最大元素  $c_{ij}$ , 则判定目标  $\hat{x}^s(i)$  和目标  $x^r(j)$  关联;

(2) 然后, 从关联系数矩阵  $C(i, j)$  中删除最大元素  $c_{ij}$  所对应的行和列元素, 得到新的降阶关联矩阵  $C_1(i, j)$ , 但原矩阵的行、列号 (即数据中对应的目标) 保持不变, 从降阶矩阵  $C_1(i, j)$  中找到新的最大值以判定该下标对应目标的关联;

(3) 重复上述过程直到求出降阶关联矩阵  $C_{N-1}(i, j)$  中的最大元素。

### 3 仿真分析

为充分验证自适应关联模型算法的有效性,分别进行数据集构建、仿真场景验证和对比实验。根据实际情况,在仿真实验中考虑了 4 种仿真场景,分别验证所提模型算法在处理舰船编队队形变换、定位误差、虚警、漏检等情况时的适应能力。在对比试验中,将传统 GMM 算法与本文模型算法进行对比。仿真场景验证和对比实验都采用了 20 000 组训练集和 20 000 组测试集。整个实验是在 Tensorflow 框架下的一个 64 位工作站上进行的,该工作站主要配置为 Ubuntu 16.04、32gb RAM、8intel(R)Core(TM) i7-6770kcpu 和 NVIDIA GTX 1080Ti×2。

#### 3.1 数据集构建

根据舰船编队实际场景,首先构建训练数据集。卫星数据的生成是通过对其某一单元区域内随机选取 11 个目标点(即  $N=11$ )。假设雷达上报数据时间晚于卫星上报数据时间,将卫星数据进行平移得到雷达数据,在平移过程中涉及的参数有  $x$  坐标轴平移量  $\Delta x \in [-5, 5]$ ,  $y$  坐标轴平移量  $\Delta y \in [-5, 5]$ 。考虑到舰船的队形可能发生变化,即雷达数据中的位置坐标点发生了非刚性形变,引入形变因子  $l$ 。

测试数据集的构建大致与训练数据相同。主要考虑以下 4 种场景。

(1) 仿真场景 1:考虑到两种观测手段存在时间间隔。在此期间,舰船编队发生位移和队形变化,即雷达数据相对于卫星数

据发生平移和非刚性形变,具体参数设置与训练集构建相同。

(2) 仿真场景 2:考虑到两种观测手段所获取的数据在定位精度上存在偏差。在场景 1 基础上对雷达数据  $G$  中的每个位置坐标点添加位置噪声。位置噪声采用均值  $u_{\text{noise}} = 0$ ,标准差  $\sigma_{\text{noise}} = f$  的高斯噪声,其中  $f$  为噪声因子。

(3) 仿真场景 3:考虑到获取的数据可能存在虚警点,在场景 2 基础上对雷达目标点集合  $G$  中添加  $N \times r$  个出格点,其中  $r$  为出格点比率。

(4) 仿真场景 4:考虑到获取的数据可能存在漏警点,在场景 2 基础上对雷达目标点集合  $G$  中减少  $N \times s$  个缺失点,其中  $s$  为缺失点比率。

#### 3.2 仿真场景验证

##### (1) 仿真场景 1

假设雷达和卫星检测概率为 100%,即不存在虚警和漏警点。雷达数据的获取时刻晚于卫星数据的获取时刻,在这段时间内舰船编队发生机动,队形产生形变。通过增加形变因子  $l$  的值,验证模型对舰船编队发生队形变化的适应能力。 $l$  越大则雷达数据目标点发生非刚性形变的形变量越大,实验结果如图 4 所示。第 1 列表示训练前卫星和雷达目标点的位置关系,其中红色代表卫星探测到的目标点,而蓝色代表雷达探测到的目标点。第 2 列表示位移变换时每个卫星目标点的移动轨迹。第 3 列表示经过目标点位移变换后卫星数据与雷达数据的目标点位置关系。实验分别测试了  $l$  分别取 0.3、0.9 和 1.5 时的匹配效果。

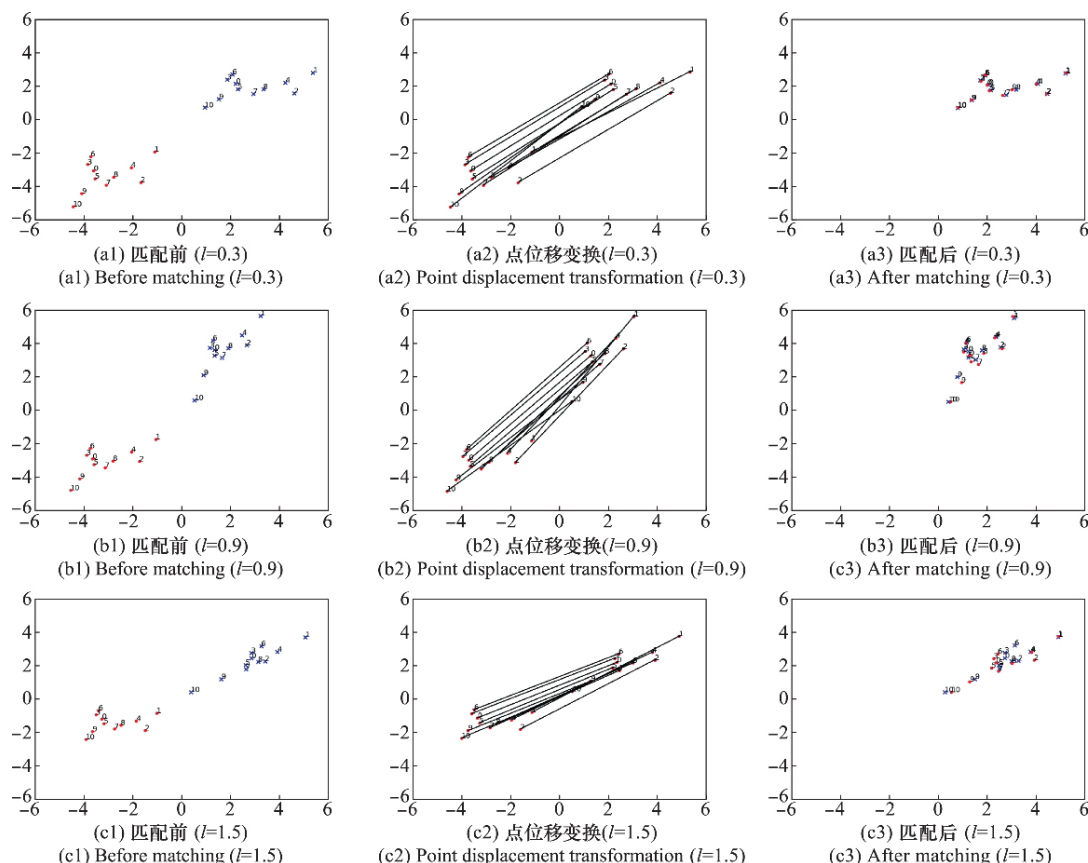


图 4 仿真场景 1 的关联结果

Fig. 4 Association results of simulation scene one



实验结果表明,形变因子较小时匹配结果精确,有相同标号的点几乎完全重合;随着形变因子增大,雷达目标的整体编队结构产生剧烈变化,加大了匹配难度。从最终匹配结果可以看出,虽然部分点没有完全重合,但有相同标号的点距离更近。根据第2.3节中定义的关联判别准则计算, $l$ 分别取0.3、0.9和1.5时的关联准确率分别为100%、81%、64%。

#### (2) 仿真场景2

假设雷达和卫星数据不存在虚警和漏警点。雷达数据的获取时刻晚于卫星数据的获取时刻,在这段时间内舰船编队发生机动,队形产生形变,形变因子 $l=0.3$ 。通过增加噪声因子 $f$ 的值,验证模型的抗噪声能力。实验结果如图5所示,实验分别测试了 $f$ 分别取0.1、0.3和0.5时的匹配效果。

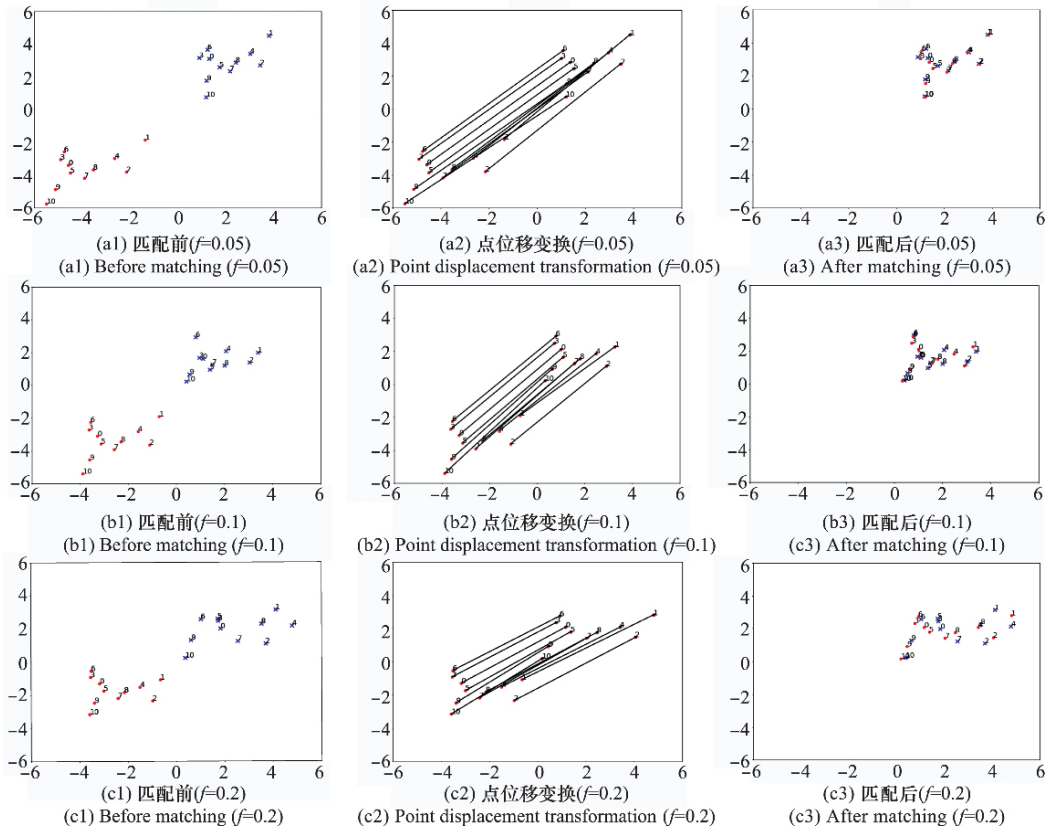


图5 仿真场景2的关联结果

Fig. 5 Association results of simulation scene two

实验结果表明,噪声因子较小时,经过目标点位移变换后的卫星数据与雷达数据目标点匹配结果精确,重合度高。当噪声因子增大,雷达目标点的相对位置发生较大改变时,通过本文提出的自适应关联模型后,卫星数据与雷达数据目标点匹配结果较差,但单纯依靠位置信息,人眼难以判别。根据第2.3节中定义的关联判别准则计算, $f$ 分别取0.05、0.1和0.2时的关联准确率分别为100%、64%、36%。

#### (3) 仿真场景3

假设雷达数据存在虚警,在雷达数据中添加额外的出格点,虚警率用出格点比率表示。雷达数据的获取时刻晚于卫星数据的获取时刻,在这段时间内舰船编队发生机动,队形产生形变,形变因子 $l=0.3$ ,噪声因子 $f=0.05$ 。通过增加出格点比率 $r$ 的值,验证模型的抗虚警能力。实验结果如图6所示,实验分别测试了 $r$ 分别取0.09、0.27和0.45时的目标匹配效果。

实验结果表明,当出格点的个数较少时,提出的模型结构能够很好地忽略掉出格点,保持卫星数据和雷达数据目标点间的匹配;当出格点个数较多时,与密集出格点临近的目标在匹配时受到影响,发生错匹配,但离出格点较远的目标依然能够保持很好的局部完整性,匹配结果精确。根据第2.3节中定义的关联判别准则计算, $r$ 分别取0.09、0.27和0.45时的关联准确率分别为100%、64%、55%。

#### (4) 仿真场景4

假设雷达数据存在漏警,随机删除雷达数据中的目标点作为缺失点,漏警率用缺失点比率表示。雷达数据的获取时刻晚于卫星数据的获取时刻,在这段时间内舰船编队发生机动,队形产生形变,形变因子 $l=0.3$ ,噪声因子 $f=0.05$ 。通过缺失点比率 $s$ 的值,验证模型的抗漏警能力。实验结果如图7所示,实验分别测试了 $s$ 分别取0.09、0.27和0.45时的目标匹配效果。

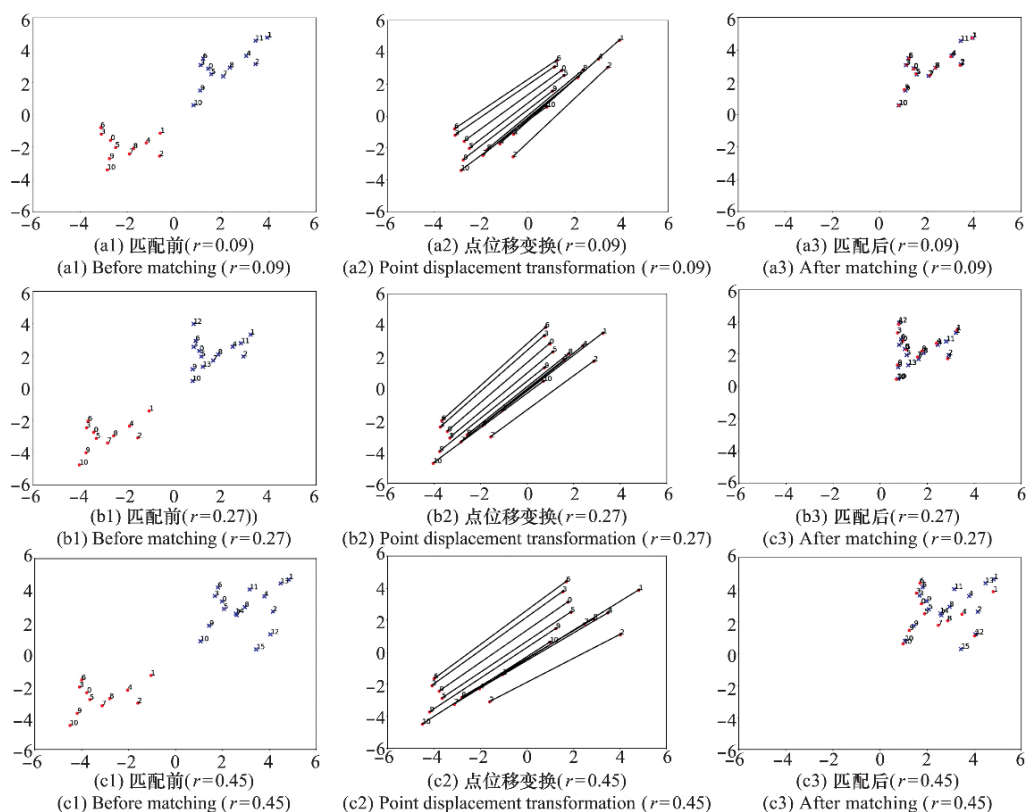


图 6 仿真场景 3 的关联结果

Fig. 6 Association results of simulation scene three

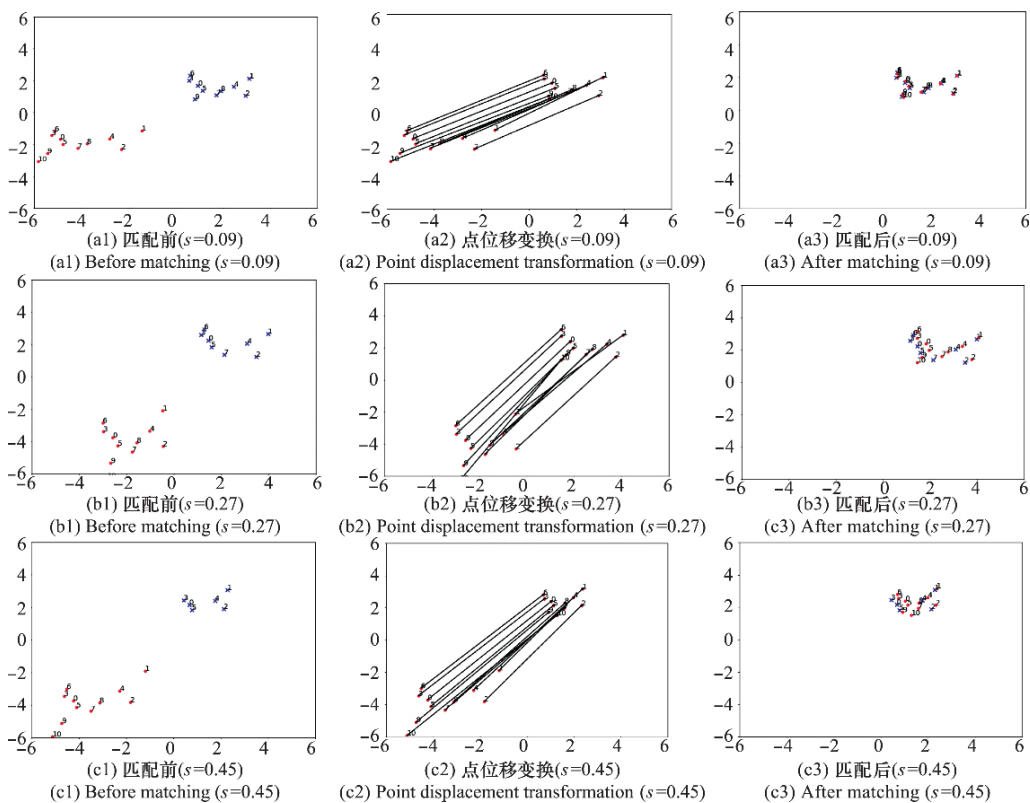


图 7 仿真场景 4 的关联结果

Fig. 7 Association results of simulation scene four

实验结果表明,缺失点个数较小时,能够保持雷达数据中编队目标的整体轮廓,匹配结果精确;当缺失点个数较多时,只能保持编队目标的局部轮廓,部分局部点匹配正确。根据第 2.3 节中定义的关联判别准则计算, $s$  分别取 0.09、0.27 和 0.45 时的关联准确率分别为 90%、75%、67%。

### 3.3 对比试验

与现有的传统关联模型不同,本文提出一种学习型的

自适应关联模型,为了验证该模型的泛化能力和关联效率,与 GMM 进行对比时主要考虑关联耗时和平均关联准确率两项指标。

根据本文模拟的 4 种仿真场景,计算不同条件下模型在测试集中的平均关联准确率,实验结果如图 8 所示。

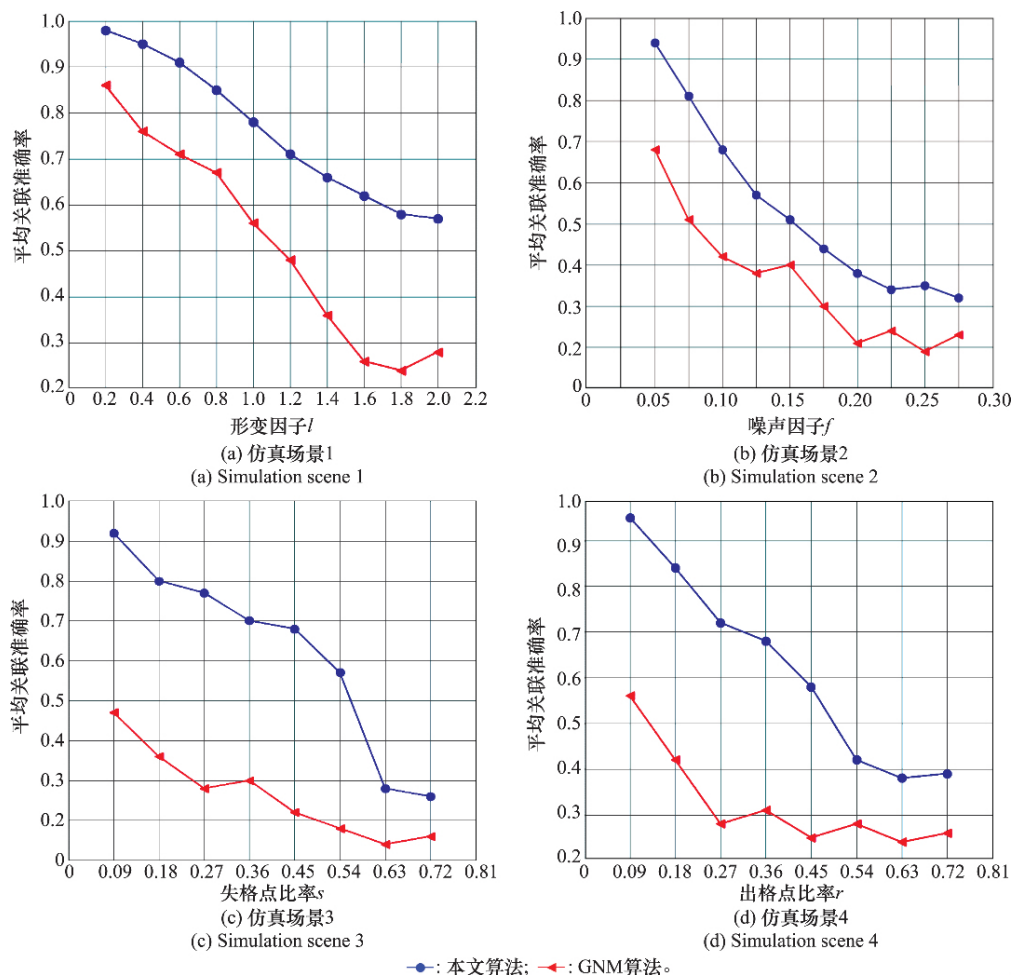


图 8 与 GMM 算法实验结果对比

Fig. 8 Experimental results comparison with GMM algorithm

在图 8(a)中,当雷达目标点发生非刚性变换,本文算法相比于 GMM 算法适应能力更强。当形变因子小于 0.6 时,本文算法的平均关联准确率在 90%以上,而 GMM 算法的最高平均关联准确率不到 90%。随着形变程度的增加,本文算法的准确率缓慢下降,而 GMM 算法下降较快,无法应对较大的非刚性形变。当形变因子达到 2.0 时,本文算法准确率依然能够达到 50%以上,而 GMM 算法准确率不到 30%,难以进行关联。

在图 8(b)中,随着噪声因子的增加,两种算法的准确率都下降较快,难以克服高噪声的情况,但本文算法的关联准确率整体优于 GMM 算法。在图 8(c)和图 8(d)中,本文算法在应对出格点和失格点的情况明显优于 GMM 算法,

当出格点个数较少时,关联准确率较于 GMM 算法提升较大,表明本文算法不仅能够实现目标点的全局关联,对局部目标点依然能够保持很好关联效果。

根据仿真场景 1 中的参数设置,对比本文算法和 GMM 算法在形变因子为 0.9 时的平均关联准确率和关联时间,实验结果如表 3 所示。

表 3 与 GMM 算法的性能和时间对比

Table 3 Performance and time comparison with GMM algorithm

方法	平均关联准确率	关联时间
GMM 算法(训练)	0.671 7	约 32 h
本文算法(训练)	0.846 6	约 6 min
GMM 算法(测试)	0.663 2	约 32 h
本文算法(测试)	0.841 3	约 8 s

实验结果表明,本文算法在平均关联准确率和关联时间上明显优于 GMM 算法,表现出很好的关联精度和效率。这主要因为传统的 GMM 算法采用迭代优化的策略,不同场景中每一次关联过程都是相互独立的,极大程度上限制了该算法在应对大规模关联任务时的有效性。而本文算法采用基于学习的策略,能够通过神经网络进行离线训练,同时学习到目标点的全局和局部特征,在测试时关联精度高,耗时少,能够实时处理大规模的关联任务。

## 4 结 论

本文提出了卫星和雷达的位置数据关联新问题,基于神经网络设计了一种自适应的关联算法模型,根据实际情况构建基于位置信息的卫星和雷达关联数据集。仿真结果表明:该算法关联速度快,精度高,能够适用于大规模数据下的跨源关联任务,并且在应对队形变换、定位误差、虚警漏报等情况适应能力强,即使出现整体编队形状变化大到人工难以关联判断的程度,所提算法也能给出正确有效的关联结果。

为进一步提高跨源关联准确率,应对大形变、高噪声等恶劣场景,下一步将采用卫星和雷达的位置数据和特征数据相结合的方式解决两者之间的关联问题,进一步提高跨源关联效率和准确率。

## 参考文献:

- [1] BAR S Y, FORTMAN T E. Tracking and data association[M]. Orlando: Academic Press, 1998.
- [2] 李文超, 邹焕新, 雷琳, 等. 目标数据关联技术综述[J]. 计算机仿真, 2013, 16(3):5-10.  
LI W C, ZOU H X, LEI L, et al. A survey of target data association[J]. Computer Simulation, 2013, 16(3):5-10.
- [3] ASHRAF M, AZI Z. Fuzzy track-to track association and track fusion approach in distributed multisensor-multitarget multiple-attribute environment[J]. Signal Processing, 2007, 87(6): 1474-1492.
- [4] PANNETIER B, NIMIER V, ROMBAUT M. Multiple ground target tracking[J]. Aerospace Science and Technology, 2007, 11(4): 271-278.
- [5] BLANDING W R, WILLETT P K, BAR S Y. Multiple target tracking using maximum likelihood probabilistic data association[C] // Proc. of the IEEE Aerospace Conference, 2007.
- [6] PAN X, WU Y. Modeling and simulations of ECCM of ocean surveillance satellite electronic intelligence[C] // Proc. of the IEEE International Conference on Biomedical Engineering & Informatics, 2013.
- [7] RICHARD J, ENJOLRAS V, SCHOESER C, et al. An innovative spaceborne radar concept for global maritime surveillance: description and performance demonstration[C] // Proc. of the IEEE International Geoscience & Remote Sensing Symposium, 2010.
- [8] CHE X, MI J, CHEN D. Information fusion and numerical characterization of a multi-source information system [J]. Knowledge-Based Systems, 2018, 145(1): 121-133.
- [9] LEE J, HONG S, MOON N, et al. Acoustic sensor based multiple object tracking with visual information association[J]. Journal on Advances in Signal Processing, 2010, 2010(1):1-19.
- [10] BOUKEZZOULA R, COQUIN D, NGUYEN T L, et al. Multi-sensor information fusion: combination of fuzzy systems and evidence theory approaches in color recognition for the NAO humanoid robot[J]. Robotics & Autonomous Systems, 2018, 100:302-316.
- [11] 田明辉, 方青, 任清安. 机载与雷达航迹融合仿真系统研究[J]. 雷达科学与技术, 2012, 10(1):64-70.  
TIAN M H, FANG Q, REN Q A. Simulation of track fusion of airborne ESM and radar[J]. Radar Science and Technology, 2012, 10(1):64-70.
- [12] 关欣, 彭彬彬, 衣晓. 修正极坐标系下雷达与 ESM 航迹对准关联[J]. 航空学报, 2017, 38(5):221-232.  
GUAN X, PENG B B, YI X. Track alignment-association of radar and ESM in MPC[J]. Acta Aeronautica ET Astronautica Sinica, 2017, 38(5):221-232.
- [13] 曾浩, 邵锡军, 王博. 基于电子侦察和雷达组网的信息协同方法研究[J]. 信息化研究, 2008, 34(12):1-3.  
ZENG H, SHAO X J, WANG B. A study on information co-ordination method based on electronic reconnaissance and radar network[J]. Electronic Engineer, 2008, 34(12):1-3.
- [14] SUN H, ZOU H X, JI K, et al. Combined use of optical imaging satellite data and electronic intelligence satellite data for large scale ship group surveillance[J]. Journal of Navigation, 2014, 68:383-396.
- [15] JAMES L. A mathematical theory of evidence[J]. The Artificial Intelligence Magazine, 1976, 20(1): 106.
- [16] ZOU H, SUN H, JI K, et al. Multimodal remote sensing data fusion via coherent point set analysis[J]. IEEE Geoscience and Remote Sensing Letters, 2013, 10(4):672-676.
- [17] DENG W X, ZOU H X, GUO F, et al. A robust non-rigid point set registration method based on inhomogeneous Gaussian mixture models[J]. The Visual Computer, 2017, 34:1007.
- [18] JIAN B, VEMURI B C. Robust point set registration using Gaussian mixture models[J]. IEEE Trans. on Pattern Analysis and Machine, 2011, 33:1633-1645.
- [19] MYRONENKO A, SONG X. Point set registration: coherent point drift[J]. IEEE Trans. on Pattern Analysis and Machine, 2010, 32(12):2262-2275.
- [20] TAO W B, SUN K. Robust point sets matching by fusing feature and spatial information using non-uniform Gaussian mixture models[J]. IEEE Trans. on Image Processing, 2015, 24(11):3754-3767.
- [21] BORGEFORS G. Hierarchical chamfer matching: a parametric edge matching algorithm[J]. IEEE Trans. on Pattern Analysis and Machine, 1988, 10(6):849-865.

## 作者简介:

熊振宇(1995—),男,硕士研究生,主要研究方向为多源信息融合、计算机视觉。

E-mail:x\_zhen\_yu@163.com

崔亚奇(1985—),男,讲师,博士,主要研究方向为多源信息融合、模式识别。

E-mail:cui\_yaqi@126.com

熊伟(1975—),男,教授,博士研究生导师,博士,主要研究方向为多源信息融合、模式识别。

E-mail:xiongwei@csif.org.cn

顾祥岐(1995—),男,博士研究生,主要研究方向为多源信息融合、目标跟踪。

E-mail:guxiangqi1314@163.com