

# 生成式中断航迹接续关联方法

徐平亮, 崔亚奇\*, 熊 伟, 熊振宇, 顾祥岐

(海军航空大学信息融合研究所, 山东 烟台 264001)

**摘 要:** 传统中断航迹接续关联(track segment consecutive association, TSCA)方法基于假设的目标运动模型,利用大量先验信息完成关联任务,存在参数过多、计算复杂、推理时间长等缺点。为了解决以上问题,提出一种基于注意力机制的生成式 TSCA 方法。首先设计航迹态势图生成模块,将原始航迹数据转换为航迹态势图,作为生成对抗网络的输入。针对航迹噪声影响大和航迹运动特征、中断特征难以提取的问题,基于生成对抗网络和注意力机制,设计航迹关联网络,滤除航迹噪声并完成 TSCA。仿真结果证明了所提网络的有效性,在关联精度和关联速度两方面都超过现有算法。

**关键词:** 中断航迹接续关联; 生成对抗网络; 注意力机制; 航迹态势图

**中图分类号:** V 19

**文献标志码:** A

**DOI:**10.12305/j.issn.1001-506X.2022.05.15

## Generative track segment consecutive association method

XU Pingliang, CUI Yaqi\*, XIONG Wei, XIONG Zhenyu, GU Xiangqi

(Research Institute of Information Fusion, Naval Aviation University, Yantai 264001, China)

**Abstract:** Traditional track segment consecutive association (TSCA) methods are based on the hypothesis target motion model and need to use a lot of prior information. It has many disadvantages such as too many parameters, complicated calculation and long reasoning time. In order to solve the above problems, a generative TSCA method based on the attention mechanism is proposed. Firstly, the module of generating the track situation map is designed, and the original track data is converted into the track situation map as the input of generative adversarial network. Aiming at the problems of track noise and the difficulty in extracting the features of track motion and track interruption, based on the generative adversarial network and the attention mechanism, the track association network is designed to filter out the noise of tracks and accomplish TSCA. The simulation results show that the proposed method is effective and exceeds the existing algorithms in both precision and speed.

**Keywords:** track segment consecutive association (TSCA); generative adversarial network; attention mechanism; track situation map

## 0 引 言

在雷达数据处理领域,目标跟踪、态势感知、信息融合等任务特别依赖于航迹段关联,如果航迹发生中断,将会对这类任务产生十分恶劣的影响,造成巨大的损失。引发航迹中断的原因有很多,例如目标的高速机动、故意停止;传感器的检测概率低、采样间隔长;杂波以及电磁干扰等<sup>[1]</sup>。为了对中断航迹进行拼接,为下游任务奠定良好的基础,各

类中断航迹接续关联算法被提出。这些算法可以分为两类:预测法和相似性度量法。

一条中断的航迹可以看成两部分:断前航迹和断后航迹。预测法将断前航迹向前预测,断后航迹向后预测(平滑),从而修复中断区间并完成关联<sup>[1-3]</sup>。各种预测法之间的区别在于使用了不同的航迹预测方法。例如 Yeom 等<sup>[1]</sup>采用基于卡尔曼滤波的离散优化方法预测并连接新老航迹。然而卡尔曼滤波不能对目标运动的概率密度函数进行

收稿日期:2021-01-30; 修回日期:2021-05-28; 网络优先出版日期:2021-09-10。

网络优先出版地址:https://kns.cnki.net/kcms/detail/11.2422.TN.20210910.1808.017.html

基金项目:国家自然科学基金(61790554, 62001499)资助课题

\* 通讯作者。

引用格式:徐平亮,崔亚奇,熊伟,等.生成式中断航迹接续关联方法[J].系统工程与电子技术,2022,44(5):1543-1552.

**Reference format:** XU P L, CUI Y Q, XIONG W, et al. Generative track segment consecutive association method[J]. Systems Engineering and Electronics, 2022, 44(5): 1543-1552.

准确建模,只有当目标运动的非线性特征和非高斯噪声保持在合理范围之内时,卡尔曼滤波才能有较好的跟踪效果,而当目标运动的非线性特征和非高斯噪声变得剧烈后,该方法的跟踪性能便会急剧下降,不能对目标进行有效跟踪。Sun 等<sup>[2]</sup>采用期望最大化算法<sup>[4]</sup>估计机动目标的运动状态来进行航迹的预测,该预测过程考虑到了模型的隐式依赖关系,即位置、速度、加速度、角速度等运动属性之间的相互依赖关系,从而对非线性运动具有较好的适应性。然而,以上跟踪算法在面对移动-停止-移动目标时,由于目标的移动速度低于雷达的最小检测速度(minimum detectable velocity, MDV),传感器无法准确识别目标的停止状态,导致关联效果恶化。为了解决该问题,Zhang 等<sup>[3]</sup>使用基于状态相关转移概率的交互式多模型估计器(interacting multiple model-estimator with state-dependent mode transition probabilities, IMM-SDP)预测新老航迹的运动状态进行航迹段的关联。在该方法中,对快速目标采用零跳跃概率的模式转换矩阵,对慢速目标采用非零跳跃概率的模式转换矩阵。简而言之,该方法在交互式多模型(interacting multiple model, IMM)中加入了“停止模型”,对停等目标具有较好的适应性,但对于正常运动目标的跟踪精度会下降。预测法需要对航迹数据进行复杂计算,关联耗时较大,且在密集复杂环境下算法的关联效果会严重恶化。相似性度量法利用航迹段之间的相似性判断两条航迹段是否属于同一目标,这类算法的关键是寻找一种合适的航迹相似性度量方法以使判断更加准确<sup>[5-7]</sup>。Zhu 等<sup>[5]</sup>提出使用局部航迹的结构化特征来衡量航迹段之间的相似性。杜渐等<sup>[6]</sup>基于模糊数学理论,提出航迹模糊相似度的概念。刘颖等<sup>[7]</sup>定义了两种局部航迹不确定度,改进了相似度计算方法,增加反馈回路,使得新算法能在一定条件下减弱系统误差的影响,可以自适应不同场景的航迹特征,自适应达到关联目的。相似性度量方法都是根据需要关联的目标所处的环境,基于预先定义的度量公式进行关联,缺乏能够对环境自适应的相似性度量方法。

不管是预测法还是航迹相似性度量法,都是基于假设的目标运动模型,采用统计估计理论进行中断航迹接续关联。两种方法都存在假设不合理、模型不适用、门限无法确定等问题。虽然 Qi 等<sup>[8]</sup>提出利用目标属性、目标运动特征、目标运动场景等先验信息以减少对于目标运动模型的依赖,但无法从根本上解决该类算法的缺陷,仍需要投入大量的人力物力进行先验信息的获取和参数调试,同时由于复杂的计算导致关联过程需要大量的推断时间,大大削减了算法的实用价值。

中断航迹接续关联问题可以看作一种转化问题:将中断的航迹转化为连续的航迹。鉴于大量图与图之间的转化任务<sup>[9-16]</sup>,使用生成对抗网络(generative adversarial network, GAN)<sup>[17]</sup>并取得了较好的效果。针对传统方法存在的问题,本文提出基于注意力机制的生成式中断航迹接续

关联方法完成中断航迹接续关联任务。首先设计航迹态势图生成模块,利用原始航迹数据构建航迹态势图作为生成对抗网络的输入。针对航迹噪声影响大和航迹中断特征难以提取的问题,设计航迹关联网络,滤除航迹噪声并生成完整航迹。与自然图像相比,航迹态势图中的特征信息明显减少,而航迹的关联更需要关注航迹中断位置的细节信息,所以本文在航迹关联网络中添加了注意力机制<sup>[18]</sup>,提高网络生成细节的能力。最后通过仿真实验证明该网络对于各类场景下的航迹中断均有较好的关联效果,且关联精度和速度均超过现有算法。

文章结构安排如下:第 1 节介绍本文提出的方法,主要包括航迹态势图生成模块、航迹关联网络和注意力模块的构成以及损失函数的理论分析;第 2 节介绍仿真数据集即航迹关联数据集的构建方法;第 3 节进行网络训练和网络结构参数选择;第 4 节进行网络测试和对比分析,包括与其他中断航迹接续关联(track segment consecutive association, TSCA)算法对比、模型适应性测试和抗噪声测试,以验证生成式中断航迹接续关联方法的有效性。

## 1 模型和方法

生成式 TSCA 方法包含 3 个模块:航迹态势图生成模块、航迹关联网络模块以及注意力模块。该方法利用 GAN 提取中断航迹态势图(interruptive track situation map, ITSM)中的航迹位置信息和中断信息,并生成连续航迹态势图(continuous track situation map, CTSM),完成中断航迹接续关联。航迹态势图生成模块将原始航迹数据转化为航迹态势图,便于之后的航迹关联网络进行处理。航迹关联网络滤除航迹噪声,提取航迹位置特征和中断特征并进行中断航迹关联(track segment association, TSA),生成 CTSM。为了加强航迹关联网络对于中断位置的敏感性,在该网络中加入了注意力模块。最后分析航迹关联网络的损失函数,证明该网络的理论可行性。本文所述方法的原理如图 1 所示。

### 1.1 航迹态势图的构建

由于 GAN 的输出为连续实数分布而无法产生离散空间的分布,难以直接处理离散的原始航迹向量<sup>[19]</sup>,所以在使用 GAN 生成连续航迹之前,通过构建航迹态势图生成模块,将离散的原始航迹向量变成连续的航迹态势图,便于之后的 GAN 进行处理。由于不同场景下的航迹坐标大小不统一,无法直接映射到同一张图中,所以需要原始航迹向量进行归一化,将航迹位置坐标限制在 $[0, 1]$ 之间,以统一航迹态势图的大小并减少航迹位置分布差异带来的影响。假设第  $i$  个航迹向量为

$$\mathbf{H}_i = [(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)]^T, i \in [1, N] \quad (1)$$

式中: $n$  为该航迹向量包含的航迹点数; $N$  为总的航迹向量的个数; $x_j^i$  表示第  $j$  个航迹向量中的第  $i$  个航迹点的  $X$  轴坐标; $y_j^i$  表示第  $j$  个航迹向量中的第  $i$  个航迹点的  $Y$  轴坐标。

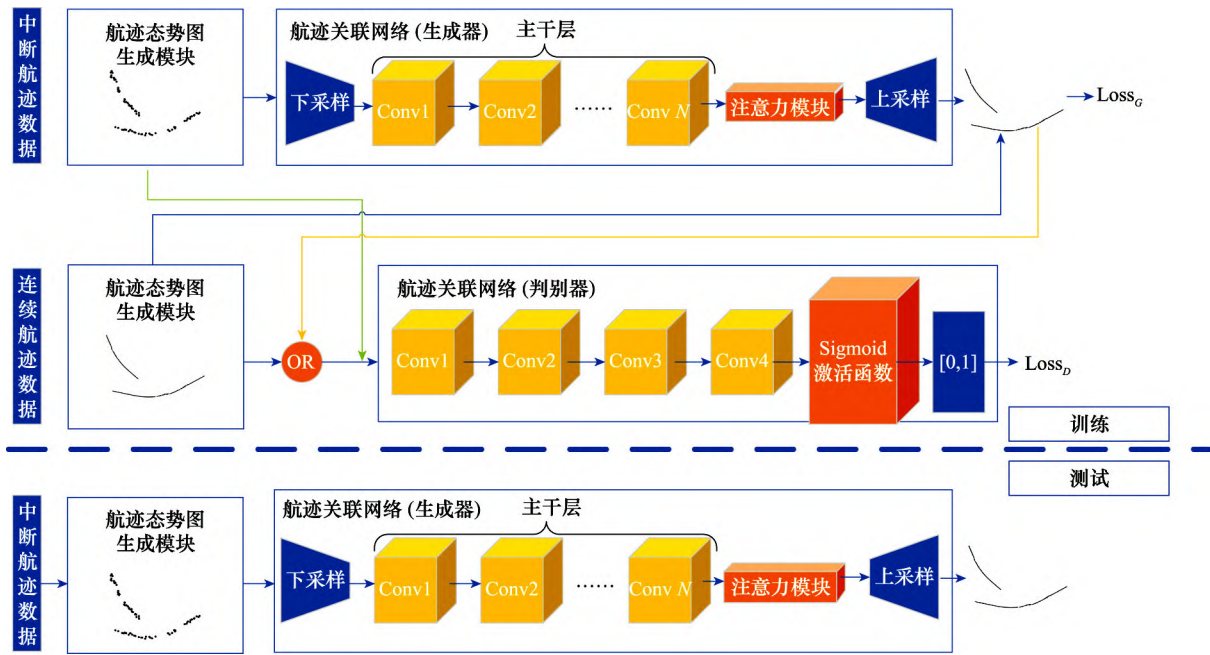


图1 原理框图

Fig. 1 Diagrammatic layout

首先,遍历所有航迹向量中的所有航迹点,分别找到  $X$  轴的最大值:

$$x_{\max} = \max_{\substack{j=1:N \\ i=1:n}} x_i^j \quad (2)$$

和  $Y$  轴的最大值:

$$y_{\max} = \max_{\substack{j=1:N \\ i=1:n}} y_i^j \quad (3)$$

构成最大值点  $[x_{\max}, y_{\max}]$ 。分别找到  $X$  轴的最小值:

$$x_{\min} = \min_{\substack{j=1:N \\ i=1:n}} x_i^j \quad (4)$$

和  $Y$  轴的最小值:

$$y_{\min} = \min_{\substack{j=1:N \\ i=1:n}} y_i^j \quad (5)$$

构成最小值点  $[x_{\min}, y_{\min}]$ 。之后将所有航迹向量中的每一个点都减去最小值点并除以最大值点与最小值点的差,得到规范、无量纲的归一化航迹向量,如下所示:

$$H'_i = \frac{H_i - [x_{\min}, y_{\min}]}{[x_{\max}, y_{\max}] - [x_{\min}, y_{\min}]} \quad (6)$$

式中:  $H'_i$  表示归一化航迹向量。在计算过程中涉及扩维变换,将最大值点  $[x_{\max}, y_{\max}]$  和最小值点  $[x_{\min}, y_{\min}]$  扩维成与  $H_i$  同样大小的向量。假设航迹向量  $H_i$  的大小为  $(n, 2)$ ,而最大值点  $[x_{\max}, y_{\max}]$  的大小为  $(1, 2)$ ,此时无法进行向量运算,利用扩维操作将  $[x_{\max}, y_{\max}]$  复制为  $n$  行,使其与  $H_i$  的大小相同,即可进行向量运算。

接着,根据需要设置空白图的大小为  $M \times M$ ,  $M$  为图的像素大小,可以看作航迹态势图的转化精度,  $M$  越大,航迹态势图的像素越大,对航迹的描绘越精细,但处理时间也相应增加,用单位长度除以  $M$  进行网格量化即  $1/M$  表示量化网格中每一像素代表的归一化航迹长度。以网格左下角为原点,每一个量化网格代表一个航迹位置点,将归一化航迹

坐标与量化网格坐标一一对应,得到航迹态势图,如图2所示。




图2 航迹态势图示意图

Fig. 2 Schematic diagram of track situation map

## 1.2 注意力模块

为了让航迹关联网络能够更好地提取航迹中断位置的细节特征,有效判断目标的运动模式,本文在该网络中的特征提取层的最后一层加入了注意力模块。注意力模块的结构如图3所示,其中  $C, H, W$  分别代表航迹态势图的通道数、高度和宽度。该注意力模块包含两部分:通道注意力和空间注意力。通道注意力的作用是计算网络提取的航迹特征中不同通道的权重,之后对输入航迹特征中各个通道进行加权,从而选择观测目标航迹的最佳观测尺度;空间注意力的作用是计算网络提取的航迹特征中不同位置的权重,之后对输入航迹特征中不同位置进行加权,提高网络对目标运动状态变化规律的的关注程度,从而选择最有利于进行

中断航迹接续关联的目标运动状态。最后将经过通道注意力和空间注意力加权后的航迹特征进行相加融合,得到注意力融合航迹特征。

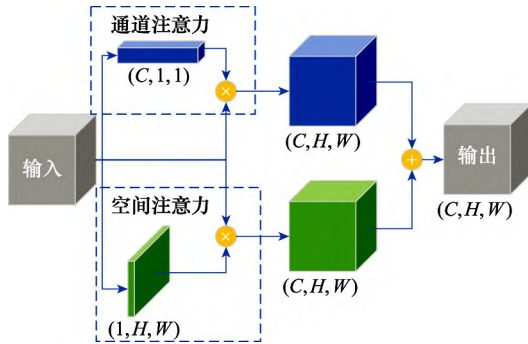


Fig. 3 Structure diagram of attention module

### 1.2.1 通道注意力

通道注意力用来从不同的尺度观测目标航迹,假设网络的特征提取层的最后一层输出张量的大小为  $(C, H, W)$ ,通道注意力模块  $(C, 1, 1)$  将给不同的通道以不同的权重并更加关注对于目标任务重要的通道。对于网络最后一层输出的特征图而言,不同的通道代表着不同的特征。对于航迹图而言,单层通道包含航迹的空间信息,多个通道之间包含航迹的观测尺度信息。为了选择重要的观测尺度,本文通过使用通道注意力模块学习通道注意力矩阵  $M_c$  来完成这一目标。通道注意力模块结构图如图 4 所示。




Fig. 4 Structure diagram of channel attention module

通道注意力的计算包括 3 个步骤:压缩、激活和加权。首先由全局平均池化层 (Avgpool) 把每个通道内各个元素相加再平均,对原始输入取全局平均值。假设输入的特征为  $T$ ,平均池化层对特征  $T$  中的一个通道的计算如下所示:

$$\text{Avgpool}(T) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W T(i, j) \quad (7)$$

之后通过两个卷积层增加网络的特征提取能力。接着使用 Sigmoid 非线性激活函数使网络具有非线性性质。最后由学习到的通道注意力矩阵  $M_c$  与原输入对应通道进行加权相乘,从而增加对应通道权重:

$$\hat{T} = TM_c \quad (8)$$

### 1.2.2 空间注意力

空间注意力用来聚焦目标航迹的运动变化趋势,尤其是中断区域附近的变化趋势。与通道注意力不同的是,空间注意力只需要关注每个通道中航迹运动的变化情况,所

以空间注意力模块的张量大小为  $(1, H, W)$ 。空间注意力模块通过学习空间注意力矩阵  $M_s$  实现空间特征选择。空间注意力模块结构图如图 5 所示。




Fig. 5 Structure diagram of spatial attention module

空间注意力的计算同样包含 3 个步骤:压缩、激活和加权。其中激活和加权步骤的操作与通道注意力相同,与通道注意力不同的是,空间注意力的压缩步骤采用  $1 \times 1$  卷积层直接将通道数压缩为 1,其本质是一个空间变换,即通过  $1 \times 1$  卷积层的权重矩阵  $W_{1 \times 1}$  将特征  $T$  的通道数由  $C$  变为 1。

$$\text{Conv}1 \times 1(T) = T \times W_{1 \times 1} \quad (9)$$

之后采用  $3 \times 3$  卷积进一步增加网络的特征提取能力。

### 1.3 航迹关联网络

航迹关联网络的目标是将中断的航迹态势图转化为连续的航迹态势图,主要的功能是进行航迹噪声滤波和航迹态势图中航迹段的关联。航迹关联网络包含一个生成器和一个判别器。生成器以 ITSM 为条件生成 CTSM,判别器用来判断生成的 CTSM 是真还是假,同时为生成器的生成方向提供指导。

#### 1.3.1 生成器

航迹关联网络中的生成器用来提取 ITSM 中的点迹特征和中断特征,根据这些特征进行 TSA,得到 CTSM。由于航迹的中断特征在航迹态势图中较为稀疏,在特征提取的过程中容易丢失,所以采用添加注意力机制的自动编码-解码器<sup>[20]</sup>模型作为该网络的生成器。该生成器包含下采样层、主干层和上采样层。下采样层包含卷积层 (Conv2d),归一化层 (instance norm)<sup>[21]</sup> 和非线性激活层 (ReLU)<sup>[22]</sup>,用来粗略地提取特征:

$$\text{ReLU}(x) = \max(0, x) \quad (10)$$

考虑到航迹态势图的稀疏性,在下采样层中没有使用池化层而是使用步长为 2 的卷积层进行下采样,避免丢失过多的航迹信息。主干层可以是输出张量大小不变 (即去除池化层) 的残差网络<sup>[23]</sup> 或深度卷积网络<sup>[24]</sup>,用来精细提取特征,网络层数均为 6 层,两者之间的差异在于是否添加残差连接。注意力模块添加在主干层最后一层之后,从高级进行特征权重分配。上采样网络由反卷积网络 (TransposeConv2d)<sup>[25]</sup>、归一化层和非线性激活层组成,反卷积为卷积的逆运算,利用反卷积将提取到的航迹特征维度提升至原 ITSM 特征维度,将提取的航迹特征映射到航迹态势图中,生成可视化的 CTSM。航迹关联网络中的生成器结构如图 6 所示。






图6 航迹关联网络中的生成器结构

Fig. 6 Structure of generator in track association network

### 1.3.2 判别器

航迹滤波网络中的判别器用来提取 ITSM 和 CTSM 的特征,利用 ITSM 作为监督信息,判断 CTSM 是真还是假(生成的),并为生成器的参数更新提供指导。判别器的输入是 ITSM 和 CTSM 在图像通道维的联结,即联结后航迹态势图的大小为  $(2C, H, W)$ ,由 ITSM 提供监督信息,提高网络的判别能力。由于判别任务是一个简单的二分类问题,如果判别器的性能过强,会导致误差梯度为 0,造成生成器训练困难<sup>[26]</sup>,所以论文中采用简单的下采样网络作为判别器。判别器由卷积层、归一化层和非线性激活层(Sigmoid)组成,为减少特征损失,同样不使用池化层而用步长为 2 的卷积层代替:

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (11)$$

Sigmoid 非线性激活层将判别结果限制在 0 到 1 之间,表示判别连续航迹的真假程度。航迹关联网络中的判别器结构如图 7 所示。




图7 航迹关联网络中的判别器结构

Fig. 7 Structure of discriminator in track association network

### 1.4 损失函数

航迹关联网络的损失函数可以分为两部分:判别损失和生成损失。两种损失函数交替反向传递直至判别器和生成器达到纳什均衡<sup>[27]</sup>,完成对抗训练的目的。所谓纳什均衡,指的是对于生成器和判别器而言,任何一方单独改变决策策略都不会得到好处,这种保持稳定平衡的状态,称为纳什均衡。航迹关联网络的总体训练损失函数如下所示:

$$\min_G \max_D L_{\text{TGAN}}(G, D) = \min_G \max_D \{E_{T_i} [\log_2 D(T_i, T_c)] + E_{T_i} [\log_2 (1 - D(T_i, G(T_i)))]\} \quad (12)$$

式中:  $T_i$  和  $T_c$  分别表示 ITSM 和 CTSM;  $G$  表示航迹关联网络中的生成器;  $D$  表示航迹关联网络中的判别器;  $E$  表示求期望。

由中断航迹图像生成连续航迹图像的过程是一个随机过程,具有不确定性。根据香农信息论,这种不确定性可以由各类情况出现的概率来衡量:概率大,出现的机会多,不确

定性小;概率小,出现的机会少,不确定性大。采用信息量描述判别器和生成器的不确定性,即式(12)中的  $\log_2(\cdot)$ ,其单位为 bit。对信息量求平均即可得到信息熵。在训练过程中,首先保持  $G$  不变训练  $D$ ,在第一项  $E_{T_i} [\log_2 D(T_i, T_c)]$  中,由于  $D$  的输入来自真实样本,所以要求信息熵尽可能大;在第二项  $E_{T_i} [\log_2 (1 - D(T_i, G(T_i)))]$  中,由于  $G(T_i)$  为生成的连续航迹,所以需要  $D(T_i, G(T_i))$  尽可能小,对应信息熵也尽可能大,因此得到  $\max_D$ 。之后保持  $D$  不变训练  $G$ ,  $G$  只包含第二项  $E_{T_i} [\log_2 (1 - D(T_i, G(T_i)))]$ ,为了迷惑  $D$ ,虽然连续航迹是生成的,但仍需要  $D(T_i, G(T_i))$  尽可能大,故信息熵尽可能小,因此得到  $\min_G$ 。

判别器和生成器的训练是交替进行的,即判别损失和生成损失的梯度回传也是交替进行的,先训练判别器,再训练生成器。体现在总体损失中即训练判别器使得最大概率对 ITSM 与 CTSM 进行判别(最大化  $E_{T_i} [\log D(T_i, T_c)]$  和  $E_{T_i} [\log (1 - D(T_i, G(T_i)))]$ ),之后训练生成器与判别器进行对抗,让其无法判别航迹态势图的中断与连续(最小化  $E_{T_i} [\log_2 (1 - D(T_i, G(T_i)))]$ ),最终使得生成器生成的样本更加真实。

#### 1.4.1 判别损失

判别损失用来量化判别器的判别结果和 CTSM 真实标签之间的差异。由于判别器的输出是介于  $[0, 1]$  的连续值,因此不使用交叉熵损失而使用均方误差(mean square error, MSE)损失作为判别损失。当训练判别器时,首先使 ITSM 和数据集中的 CTSM 联结,标签为 1;之后和生成的 CTSM 联结,标签为 0。在训练生成器时,ITSM 和生成的 CTSM 联结,标签为 1,以达到欺骗判别器的目的。判别损失如下所示:

$$\text{Loss}_D = \sqrt{(l_D - l_R)^2} \quad (13)$$

式中:  $l_D$  和  $l_R$  分别表示判别器的判别结果和标签。

#### 1.4.2 生成损失

生成损失包括 L1 损失和判别损失。L1 损失被用来衡量真实连续航迹图和生成连续航迹图之间的差别,并在误差反向传递的过程中通过调节网络参数使生成的连续航迹图尽可能与真实的连续航迹图相似。由于 L1 损失更加注重度量图像细节和边缘的差异<sup>[28]</sup>,十分适合航迹态势图之间的比较,所以本文中选择 L1 损失而不使用 L2 损失。判别损失被用来为生成器的训练提供全局梯度指导,使得生成器和判别器之间的对抗产生效果。 $\lambda_{L1}$  和  $\lambda_D$  分别是 L1

损失和判别损失的权重。L1 损失如下所示：

$$\text{Loss}_{L1} = |T_G - T_R| \quad (14)$$

式中： $T_G$  是生成的 CTSM； $T_R$  是真实的 CTSM。生成损失如下所示：

$$\text{Loss}_G = \lambda_{L1} \cdot \text{Loss}_{L1} + \lambda_D \cdot \text{Loss}_D \quad (15)$$

## 2 数据集的构建

### 2.1 目标运动状态模型

本文在二维笛卡尔坐标系下构建目标航迹数据集，二维坐标下目标的运动状态可以由以下运动学标准曲线运动公式<sup>[29]</sup>来描述：

$$\dot{x}(t) = v(t) \cos \varphi(t) \quad (16)$$

$$\dot{y}(t) = v(t) \sin \varphi(t) \quad (17)$$

$$\dot{v}(t) = a_t(t) \quad (18)$$

$$\dot{\varphi}(t) = \frac{a_n(t)}{v(t)} \quad (19)$$

式中： $(x, y)$ 、 $v$ 、 $\varphi$  分别为目标在二维笛卡尔坐标系下的坐标、地速(空速加风速)、角速度； $a_t$  和  $a_n$  分别为切向加速度和法向加速度。目标的运动参数设置如下：① 设置目标初始位置、速度、加速度和航向，分别服从  $U(-10\ 000\text{ m}, 10\ 000\text{ m})$ 、 $U(-100\text{ m/s}, 100\text{ m/s})$ 、 $U(-5\text{ m/s}^2, 5\text{ m/s}^2)$  和  $U(-90^\circ, 90^\circ)$  的均匀分布；② 设置目标的运动采样点数  $N=50$ ，每隔 1 s 采样一次；③ 设置平稳运动时间  $T_s=10\text{ s}$ ，目标在这段时间保持匀速直线运动，之后随机进行航向服从  $U(-90^\circ, 90^\circ)$ ，加速度服从  $U(-5\text{ m/s}^2, 5\text{ m/s}^2)$  的运动状态变化，状态转移时间服从  $U(20\text{ s}, 40\text{ s})$ 。基于二维坐标下目标的运动公式以及目标的运动参数，构建航迹关联数据集。

### 2.2 航迹关联数据集

航迹关联数据集包括含噪声的中断航迹点迹 A 和无噪声的连续航迹 B，具体的构建过程如下：① 根据第 2.1 节中的参数设置，在达到采样点数  $N=50$  后保存目标的运动坐标，得到无噪声的目标运动航迹 B；② 对无噪声的目标运动航迹的各个坐标添加噪声，噪声的均值为 0，方差分别为 2 km、4 km、6 km，得到有噪声的目标运动航迹；③ 对有噪声的目标运动航迹进行随机截断，保存截断后的航迹为含噪声的中断航迹点迹 A。同一编号的航迹关联数据集 A 和 B 分别为航迹关联网络的输入和输出，用来进行航迹关联网络的训练。由航迹关联数据集中的一对航迹数据构成的航迹态势图如图 8 所示。





图 8 航迹关联数据集中的一对航迹态势图

Fig. 8 A pair of track situation maps in associated track dataset

## 3 网络训练与网络的结构和参数选择

为了选择最佳的网络结构和参数，进行如下仿真实验：

① 航迹关联网络生成器和判别器的下采样输出通道维数选择；② 网络中生成器的主干层网络结构选择。实验中用到的评价指标为平均关联准确率(AP)、K 目标关联准确率( $P@K$ ，K 为当前场景下的目标个数)和结构相似性(structural similarity, SSIM)<sup>[30]</sup>。其值都分布在 0 到 1 之间，值越高表示关联效果越好。假设共有 N 个仿真场景，则  $P@K$  定义如下所示：

$$P@k_i = \frac{k'_i}{k_i}, i=1, 2, \dots, N \quad (20)$$

式中： $k'_i$  表示该场景下关联正确的目标个数； $k_i$  表示第 i 个仿真场景中的目标个数。AP 的定义如下所示：

$$AP = \frac{\sum_{i=1}^N k'_i}{\sum_{i=1}^N k_i} \quad (21)$$

所有的训练和仿真实验都是在 pytorch 深度学习框架<sup>[31]</sup>下的一个 64 位工作站中进行，该工作站中与实验相关的主要配置为 Ubuntu 16.04、32GB RAM、Intel Core i7-8700 CPU @ 3.20 GHz、NVIDIA GTX 1080Ti。

### 3.1 下采样输出通道数选择

输入到生成器和判别器中的数据都是三通道红绿蓝(red green blue, RGB)图像数据，但是经过第一个下采样层之后输出的数据通道数是不确定的，选择不同的输出通道数会对网络产生不同的影响，为了探究不同的下采样输出通道数对网络性能的影响并选择最佳的输出通道数，本实验选择不同的下采样输出通道数(8, 16, 32, 64, 128, 256)进行模型训练并验证关联效果。不同的下采样输出通道数的关联结果如表 1 所示，最好结果加粗标出。

表 1 不同下采样输出通道数关联结果

Table 1 Association results output channels under different sub-sampling dimensions

输出通道	AP	$P@5$	$P@10$	$P@20$	SSIM
8	0.40	0.80	0.60	0.20	0.863 7
16	0.63	<b>1.00</b>	0.70	0.50	0.891 4
32	0.68	<b>1.00</b>	0.80	<b>0.55</b>	0.893 9
64	<b>0.71</b>	<b>1.00</b>	<b>0.90</b>	<b>0.55</b>	<b>0.904 3</b>
128	0.00	0.00	0.00	0.00	0.414 5
256	0.00	0.00	0.00	0.00	0.365 8

根据表1中的数据可以看出,当输出维度为64时网络达到最佳关联性能。维度过小或过大,都会对网络的关联效果造成不良影响。输出维度过小,网络无法充分提取航迹特征,不充分、不全面的特征造成网络对航迹中断处的关联出现错误;输出维度过大,网络提取的航迹特征过于冗余,网络易陷入过拟合,使网络局限于拟合训练集中的已知航迹,无法适用于未知航迹,造成性能急剧下降。

### 3.2 生成器主干层网络结构选择

考虑到航迹关联网络中生成器的主干层选择不同的网络结构对网络性能会造成不同的影响,现在残差网络和深度卷积网络结构中进行消融实验以选择最佳网络结构,并且下采样的输出维度选择第3.1节中得到的最佳维度64,不同主干层的关联结果如表2所示,最好结果加粗标出。

表2 不同主干层的关联结果

Table 2 Association results of different backbone layers

主干层	AP	P@5	P@10	P@20	SSIM
深度卷积网络	0.46	0.6	0.5	0.4	0.893 5
残差网络	<b>0.71</b>	<b>1.00</b>	<b>0.9</b>	<b>0.55</b>	<b>0.904 3</b>

从表2可以看出,当航迹关联网络的生成器主干层选择残差网络时,网络达到最佳关联效果,这与残差连接的影响是分不开的。由于航迹特征图中的航迹采样点较为稀疏,随着网络结构的加深,稀疏的采样点容易引发梯度消失

问题,即误差梯度无法有效回传,使得网络参数无法更新,造成航迹关联网络无法有效滤除航迹噪声,提取中断航迹特征并进行TSA。当添加残差连接后,航迹态势图中的特征可以越过卷积层传播,缓解了梯度消失问题,有效提升关联效果。

## 4 网络测试和对比分析

为了充分验证本文所提的生成式中断航迹接续关联方法的有效性,进行如下仿真实验:①与其他TSA关联效果对比;②运动模型适应性测试;③不同噪声水平关联效果对比。以下试验均采用第3节得到的最佳模型,即下采样输出维度为64,主干网络为残差网络的网络模型进行测试。

### 4.1 与传统TSA关联效果对比

本节将本文所提方法与传统TSA<sup>[32]</sup>,多假设TSA<sup>[8]</sup>和multi-frame S-D TSA<sup>[33]</sup>进行对比,构建了包含标准差为4 km噪声的仿真场景,主要考虑关联耗时和平均关联准确率两项指标。

该场景包含5个目标,在中断前后,目标均保持匀速直线运动模式,但在中断过程中,目标的运动模式可能发生改变。该场景中雷达测量周期为 $T=5$  s,每次中断间隔设为4个采样周期即 $T_{\text{interrupt}}=20$  s,仿真场景中所有目标的航迹信息如图9所示。




图9 仿真场景中所有目标的航迹信息

Fig. 9 Track information of all targets in the simulation scenario

对于传统TSA、多假设TSA和multi-frame S-D TSA采用50次蒙特卡罗仿真并计算出每次仿真的关联指标AP和所需时间,最后取平均值得到最终的关联结果。对于本文提出的方法,重复进行50次仿真,将每次得到的关联指

标AP和所需时间取平均值得到最终的关联结果。对比仿真实验的关联结果如表3所示,本方法仿真的可视化结果如图10所示,传统TSA的可视化结果如图11所示,其中上三角符号表示对于中断航迹的位置估计。

表 3 对比实验关联结果

Table 3 Association results of comparative experiments

指标	算法			
	传统 TSA	多假设 TSA	multi-frame S-D TSA	本文 方法
AP/%	42.8	94.0	97.5	100.0
t/s	0.35	0.38	1.25	0.12




图 10 本文方法可视化结果

Fig. 10 Visualization results of the proposed method




图 11 传统 TSA 的可视化结果

Fig. 11 Visualization results of traditional TSA

根据图 11 中的关联结果,可以发现对于目标 1~目标 5 的第二次中断,传统 TSA 在对新航迹进行滤波平滑的过程中由于目标位置密集、相互遮挡等原因,会导致关联错误。通过表 3 与其他 TSA 算法对比可以看出,本文提出的生成式 TSCA 方法不仅可以在观测准确率上达到最优,而且速度也远远快于已有算法,同时兼顾了质量和效率。并且对于航迹中密集的目标交叉区域,本文方法可以有效可靠地进行航迹关联,大大提升了关联效果。

#### 4.2 网络适应性测试

为了验证本文方法在实际场景中的关联效果,本节选取了 4 个运动场景对模型的适应性进行测试,4 个运动场景的设置如下:① 场景 1 包含两个相向而行的目标,在同一时刻发生航迹中断;② 场景 2 包含两个交叉运动目标,

在交叉位置附近发生航迹中断;③ 场景 3 包含两个发生两次交叉运动的目标,在两次交叉之间发生航迹中断;④ 场景 4 包含两个相切运动目标,在相切处发生航迹中断。4 个场景中的 ITSM 如图 12 所示,CTSM 如图 13 所示。




图 12 4 个场景的 ITSM

Fig. 12 ITSM for four scenarios






图 13 4 个场景的关联后 CTSM

Fig. 13 CTSM for four scenarios after association

由图 12 和图 13 对比可以看出,经过航迹关联网络的处理可以对航迹的中断位置进行关联,并且可以有效处理航迹交叉带来的不良影响,针对多次中断也能可靠有效地完成关联任务。

#### 4.3 网络抗噪声测试

以上仿真实验都是基于不含噪声的理想仿真航迹数据,但在真实环境下,获取这种无噪声的理想数据是十分困难的。为了探究本文方法的抗噪声性能,本节针对不同噪声场景进行关联效果对比。分别在无噪声数据中添加均值为 0,标准差为 2 km、4 km、6 km 的高斯噪声来模拟不同的噪声等级,测试网络的抗噪声性能。其中,仿真噪声的标准差表示噪声对于航迹采样点位置的影响。不同噪声场景下的关联效果如表 4 所示,选取了包含 5 个目标场景下各个噪声等级的关联结果如图 14 所示。

表 4 不同噪声场景下的关联效果

Table 4 Association effect under different noise scenarios

噪声等级	AP	$P@5$	$P@10$	$P@20$	SSIM
2	0.71	1.00	0.9	0.55	0.904 3
4	0.69	1.00	0.8	0.45	0.873 6
6	0.58	1.00	0.7	0.4	0.834 2

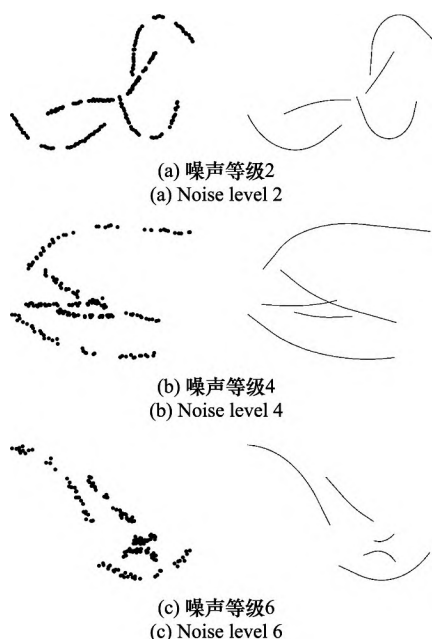


图 14 5 个目标场景下各个噪声等级的关联结果

Fig. 14 Association results of each noise level under five targets scenes

根据表 4 可以看出,在均值为 0,标准差为 6 km 的噪声条件下,本文方法对于非密集目标还能保持可靠的关联,但对于密集目标( $P@20$ ),由于噪声影响导致航迹采样点之间相互遮挡,航迹中断点的位置以及航迹的运动模式特征提取困难,关联精度稍有下降。对于标准差小于 6 km 噪声条件下的关联,本文方法都能达到较好的关联结果,证明了所提网络在噪声条件下同样具备较好的性能,完成中断航迹接续关联任务。

## 5 结 论

为了解决传统基于模型的中断航迹接续关联方法需要大量的先验信息、假设的目标运动模型以及需要对航迹数据进行复杂计算等缺点和问题,本文提出基于注意力机制的航迹关联网络完成中断航迹接续关联任务。该方法利用 GAN 自动提取航迹的运动特征和中断特征,并对航迹中断缺失部分自动关联,无须预先获得大量先验信息和目标运动模型,并且很大程度上克服了噪声的影响。通过仿真航迹数据确定了最佳网络结构和网络参数,并验证了本文方法具有较好的目标运动适应性能和抗噪声性能。通过对比实验证明所提方法在关联质量和关联速度两方面都大大优于现有算法。

## 参考文献

- [1] YEOM S W, KIRUBARAJAN T, BAR S Y. Improving track continuity using track segment association[C] // Proc. of the IEEE Aerospace Conference, 2003.
- [2] SUN J P, WANG N Y, ZHANG Z G. Track segment association of maneuvering target based on expectation maximization[C] // Proc. of the 11th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics, 2018.
- [3] ZHANG S, BAR S Y. Track segment association for GMTI tracks of evasive move-stop-move maneuvering targets[J]. IEEE Trans. on Aerospace and Electronic Systems, 2011, 47(3): 1899 - 1914.
- [4] DEMPSTER A P, LAIRD N M, RUBIN D B. Maximum likelihood from incomplete data via the EM algorithm[J]. Journal of the Royal Statistical Society: Series B (Methodological), 1977, 39(1): 1 - 22.
- [5] ZHU H Y, HAN S Y. Track-to-track association based on structural similarity in the presence of sensor biases[J]. Journal of Applied Mathematics, 2014: 294657.
- [6] 杜渐, 夏学知. 面向航迹中断的模糊航迹关联算法[J]. 火力与指挥控制, 2013, 38(6): 68 - 71.  
DU J, XIA X Z. A fuzzy track association algorithm in track interrupt-oriented[J]. Fire Control & Command Control, 2013, 38(6): 68 - 71.
- [7] 刘颖, 陈世友, 汪学东, 等. 一种自适应航迹关联算法[J]. 电子学报, 2013, 41(12): 2416 - 2421.  
LIU H, CHEN S Y, WANG X D, et al. An adaptive track correlation algorithm[J]. Chinese Journal of Electronics, 2013, 41(12): 2416 - 2421.

- 2416–2421.
- [8] 齐林, 王海鹏, 熊伟, 等. 基于先验信息的多假设模型中断航迹关联算法[J]. 系统工程与电子技术, 2015, 37(4): 732–739.
- QI L, WANG H P, XIONG W, et al. Track segment association algorithm based on multiple-hypothesis models with priori information[J]. Journal of Systems Engineering and Electronics, 2015, 37(4): 732–739.
- [9] DONG H, YU S M, WU C, et al. Semantic image synthesis via adversarial learning[C]//Proc. of the IEEE International Conference on Computer Vision, 2017: 5706–5714.
- [10] KANEKO T, HIRAMATSU K, KASHINO K. Generative attribute controller with conditional filtered generative adversarial networks[C]//Proc. of the IEEE Conference on Computer Vision and Pattern Recognition, 2017.
- [11] KARACAN L, AKATA Z, ERDEM A, et al. Learning to generate images of outdoor scenes from attributes and semantic layouts[EB/OL]. [2021–01–25]. <https://arxiv.org/pdf/1612.00215.pdf>.
- [12] LEDIG C, THEIS L, HUSZAR F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proc. of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 4681–4690.
- [13] PATHAK D, KRAHENBUHL P, DONAHUE J, et al. Context encoders: feature learning by inpainting[C]//Proc. of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2536–2544.
- [14] SANGKLOY P, LU J W, FANG C, et al. Scribbler: controlling deep image synthesis with sketch and color[C]//Proc. of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 5400–5409.
- [15] WANG X L, GUPTA A. Generative image modeling using style and structure adversarial networks[C]//Proc. of the European Conference on Computer Vision, 2016: 318–335.
- [16] ZHANG Z F, SONG Y, QI H R. Age progression/regression by conditional adversarial autoencoder[C]//Proc. of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 5810–5818.
- [17] GOODFELLOW I, POUGET A J, MIRZA M, et al. Generative adversarial nets[J]. Advances in Neural Information Processing Systems, 2014, 27: 2672–2680.
- [18] MNH V, HEES N, GRAVES A. Recurrent models of visual attention[J]. Advances in Neural Information Processing Systems, 2014, 2: 2204–2212.
- [19] WANG K F, GOU C, DUAN Y J, et al. Generative adversarial networks: the state of the art and beyond[J]. Acta Automatica Sinica, 2017, 43(3): 321–332.
- [20] VINCENT P, LAROCHELLE H, BENGIO Y, et al. Extracting and composing robust features with denoising autoencoders[C]//Proc. of the 25th International Conference on Machine Learning, 2008: 1096–1103.
- [21] ULYANOV D, VEDALDI A, LEMPITSKY V. Instance normalization: the missing ingredient for fast stylization[EB/OL]. [2021–01–25]. <https://arxiv.org/abs/1607.08022v1>.
- [22] GLOROT X, BORDES A, BENGIO Y. Deep sparse rectifier neural networks[C]//Proc. of the 14th International Conference on Artificial Intelligence and Statistics, 2011: 315–323.
- [23] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]//Proc. of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770–778.
- [24] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[EB/OL]. [2021–01–25]. <https://arxiv.org/abs/1409.1556>.
- [25] DUMOULIN V, VISIN F. A guide to convolution arithmetic for deep learning[EB/OL]. [2021–01–25]. <https://arxiv.org/abs/1603.07285>.
- [26] PENG X B, KANAZAWA A, TOYER S, et al. Variational discriminator bottleneck: improving imitation learning, inverter, and gans by constraining information flow[EB/OL]. [2021–01–25]. <https://arxiv.org/abs/1810.00821v4>.
- [27] RATLIFF L J, BURDEN S A, SASTRY S S. Characterization and computation of local Nash equilibria in continuous games[C]//Proc. of the IEEE 51st Annual Allerton Conference on Communication, Control, and Computing, 2013: 917–924.
- [28] ZHAO H, GALLO O, FROSIO I, et al. Loss functions for image restoration with neural networks[J]. IEEE Trans. on Computational Imaging, 2016, 3(1): 47–57.
- [29] LI X R, JILKOV V P. Survey of maneuvering target tracking. Part I. dynamic models[J]. IEEE Trans. on Aerospace and Electronic Systems, 2003, 39(4): 1333–1364.
- [30] WANG Z, BOVIK A C, SHEIKH H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Trans. on Image Processing, 2004, 13(4): 600–612.
- [31] PASZKE A, GROSS S, MASSA F, et al. Pytorch: an imperative style, high-performance deep learning library[EB/OL]. [2021–01–25]. <https://arxiv.org/abs/1912.01703v1>.
- [32] YEOM S W, KIRUBARAJAN T, BAR S Y. Track segment association, fine-step IMM and initialization with Doppler for improved track performance[J]. IEEE Trans. on Aerospace and Electronic Systems, 2004, 40(1): 293–309.
- [33] RAGHU J, SRIHARI P, THARMARASA R, et al. Comprehensive track segment association for improved track continuity[J]. IEEE Trans. on Aerospace and Electronic Systems, 2018, 54(5): 2463–2480.

## 作者简介

徐平亮(1997—),男,硕士研究生,主要研究方向为多源信息融合、航迹关联。

崔亚奇(1987—),男,讲师,博士,主要研究方向为多源信息融合、模式识别。

熊伟(1977—),男,教授,博士,主要研究方向为多源信息融合、模式识别。

熊振宇(1995—),男,硕士研究生,主要研究方向为多源信息融合、计算机视觉。

顾祥岐(1995—),男,博士研究生,主要研究方向为多源信息融合、目标跟踪。